



目录

1 第 1 章：概论	2
一、名词解释	2
二、回归与欠拟合/过拟合	2
五、KNN 分类模型	3
2 第 2 章：模型选择与评估	3
一、名词解释	3
四、ROC 与 AUC	3
3 第 3 章：贝叶斯分类器	5
一、名词解释	5
五、贝叶斯决策	5
六、朴素贝叶斯分类器	6
4 第 4 章：线性模型	7
一、名词解释	7
三、一对多判别边界	7
四、LDA 投影	8
七、交叉熵损失	9
5 第 5 章：决策树	9
一、名词解释	9
四、最小二乘回归树	10
五、ID3 与 CART 决策树	12
6 第 6 章：集成学习	14
一、名词解释	14
二、AdaBoost 权重迭代关系	14
三、AdaBoost 强分类过程	15
7 第 7 章：维度归约	16
一、名词解释	16
四、正交投影矩阵	16
五、PCA 与 LDA 投影方向	17
六、PCA 主分量与方差贡献率	17
8 第 8 章：聚类	19
一、名词解释	19
二、k-means 与 kNN	19
四、k-means 聚类	19
五、聚类算法选择	21

9 第 9 章：神经网络	21
一、TensorFlow 神经网络网页与二分类网络模型	21
二、名词解释	22
五、BP 神经网络一次迭代	23
六、BGD 的 BP 神经网络训练步骤	24
七、Softmax 与交叉熵	25
10 第 10 章：深度学习	26
九、卷积层参数量	26

1. 第 1 章：概论


一、名词解释

练习 1：名词解释. 解释以下概念：特征空间、假设空间、标记空间。

- 特征空间** 样本用特征向量表示后可能取值的空间。若样本有 d 个数值特征，常写为 $\mathcal{X} \subseteq \mathbb{R}^d$ ，每个样本 $x = (x_1, \dots, x_d)^T$ 是特征空间中的一个点。
- 假设空间** 学习算法可能输出的模型或函数集合，记为 $\mathcal{H}$ 。学习过程本质上是在 $\mathcal{H}$ 中根据训练数据选择一个假设 $h: \mathcal{X} \rightarrow \mathcal{Y}$ 。
- 标记空间** 监督学习中样本标记可能取值的集合，记为 $\mathcal{Y}$ 。分类任务的标记空间通常是有限类别集合，回归任务的标记空间通常是实数集或实数向量空间。

二、回归与欠拟合/过拟合

练习 2：回归与欠拟合/过拟合. 如下图是通过 GDP 对幸福度进行回归，蓝色点为已知样本，蓝色线表示回归曲线。判断模型属于欠拟合还是过拟合，并解释欠拟合、过拟合的定义、对未知样本预测的影响及解决方法。



- 图中的蓝色回归曲线剧烈振荡，在训练样本附近刻意贴合，而在样本外区域出现不合理的垂直跳变，因此属于**过拟合**。
- 欠拟合指模型复杂度不足，连训练数据中的主要规律也没有学到，表现为训练误差和测试误差都较大。过拟合指模型把训练集中的噪声或偶然性也当成规律学习，表现为训练误差很小但泛化误差较大。欠拟合时，对未知样本的预测通常偏差较大；过拟合时，对未知样本的预测方差较大，对训练集以外的数据不稳定。
- 解决过拟合的常见方法包括降低模型复杂度、增加正则化、剪枝、早停、数据增强、扩大训练集、使用交叉验证选择超参数等。解决欠拟合的常见方法包括提高模型复杂度、加入更有效的特征、减弱正则化、延长训练或选择表达能力更强的模型。

五、KNN 分类模型

练习 3: KNN 分类模型. KNN 分类模型中, K 是什么意思? 简述该模型的工作流程。

KNN 中的 K 表示参与投票的最近邻样本个数。给定测试样本 x , KNN 的基本流程是: 计算 x 与训练集中各样本的距离; 选出距离最近的 K 个样本; 分类任务中按多数表决决定类别, 回归任务中通常取邻居标记的平均值或加权平均值。 K 较小时模型更敏感、方差较大; K 较大时模型更平滑、偏差较大。

2. 第 2 章: 模型选择与评估

一、名词解释

练习 4: 名词解释. 解释以下概念: 经验误差、泛化误差、训练集、测试集、验证集、查准率、查全率、分层采样、交叉验证、自助采样。

经验误差 学习器在训练集上的平均损失, 也称训练误差。

泛化误差 学习器在未知样本总体上的期望损失, 反映模型对新数据的预测能力。

训练集 用于拟合模型参数的数据集。

测试集 训练完成后用于估计泛化性能的数据集, 原则上不参与模型选择。

验证集 训练过程中用于选择超参数、模型结构或早停轮数的数据集。

查准率 预测为正的样本中真正为正的比率, $P = \frac{TP}{TP + FP}$ 。

查全率 全部真实正例中被正确检出的比例, $R = \frac{TP}{TP + FN}$ 。

分层采样 按类别比例分别抽样, 使训练集、验证集、测试集尽量保持原始类别分布。

交叉验证 将数据划分为若干份, 轮流用其中一份验证、其余训练, 并汇总多次验证结果估计性能。

自助采样 从含 m 个样本的数据集中有放回地抽取 m 次形成训练集, 未被抽中的样本可作包外测试。

四、ROC 与 AUC

练习 5: ROC 与 AUC. 已知 8 个测试样本中有 4 个正例、4 个反例, 预测结果为

$(s_1, 0.80, +), (s_2, 0.70, +), (s_3, 0.56, -), (s_4, 0.50, +),$

$(s_5, 0.50, -), (s_6, 0.30, +), (s_7, 0.20, -), (s_8, 0.15, -).$

画出 ROC 曲线, 并给出 AUC 的值。

基本概念: ROC 曲线以假正例率 $FPR = FP/m_-$ 为横轴、真正例率 $TPR = TP/m_+$ 为纵轴, 通过移动分类阈值绘制。AUC 为 ROC 曲线下方的面积 (梯形法或排序法), 值越接近 1 分类器性能越好, 0.5 表示随机猜测。

本题正例数和反例数均为 $m_+ = m_- = 4$ 。

步骤一: 按预测分数从高到低排序。

样本	分数	真实标记
s_1	0.80	+
s_2	0.70	+
s_3	0.56	-
s_4	0.50	+
s_5	0.50	-
s_6	0.30	+
s_7	0.20	-
s_8	0.15	-

步骤二：阈值依次降低，逐个（同分时同时）将样本纳入正类预测。 s_4 与 s_5 分数相同（均为 0.50），在同一阈值处同时加入。设 TP 、 FP 为当前判断为正类的正例数和反例数，则 $TPR = TP/4$ 、 $FPR = FP/4$ 。

阈值区间	新增判为正类	TP	FP
> 0.80	无	0	0
$(0.70, 0.80]$	$s_1(+)$	1	0
$(0.56, 0.70]$	$s_2(+)$	2	0
$(0.50, 0.56]$	$s_3(-)$	2	1
$(0.30, 0.50]$	$s_4(+), s_5(-)$	3	2
$(0.20, 0.30]$	$s_6(+)$	4	2
$(0.15, 0.20]$	$s_7(-)$	4	3
≤ 0.15	$s_8(-)$	4	4

步骤三：计算各阈值对应的 (FPR, TPR) 坐标，即 ROC 曲线上的点。

(FPR, TPR)	$FPR = FP/4$	$TPR = TP/4$
$(0, 0)$	0	0
$(0, \frac{1}{4})$	0	$1/4$
$(0, \frac{1}{2})$	0	$2/4$
$(\frac{1}{4}, \frac{1}{2})$	$1/4$	$2/4$
$(\frac{1}{2}, \frac{3}{4})$	$2/4$	$3/4$
$(\frac{1}{2}, 1)$	$2/4$	$4/4$
$(\frac{3}{4}, 1)$	$3/4$	$4/4$
$(1, 1)$	$4/4$	$4/4$

ROC 曲线的几何含义：从 $(0, 0)$ 出发，先沿纵轴垂直上升（纯正例区间无 FP），遇负例后水平右移且伴随垂直上升（混合区间），最终到达右上角 $(1, 1)$ 。

步骤四：用梯形法计算 AUC。 排除垂直线段（FPR 不变的部分），只对 FPR 发生变化的四段水平/斜向线段求梯形面积：

$$\begin{aligned}
 AUC &= \frac{\frac{1}{4}}{2} \left(\frac{1}{2} + \frac{1}{2} \right) + \frac{\frac{1}{4}}{2} \left(\frac{1}{2} + \frac{3}{4} \right) + \frac{\frac{1}{4}}{2} (1 + 1) + \frac{\frac{1}{4}}{2} (1 + 1) \\
 &= \frac{1}{8} + \frac{5}{32} + \frac{1}{4} + \frac{1}{4} \\
 &= \frac{25}{32} \approx 0.7813.
 \end{aligned}$$




图 1: 8 个测试样本的 ROC 曲线

3. 第 3 章：贝叶斯分类器

一、名词解释

练习 6: 一、名词解释. 解释以下概念：后验概率、朴素贝叶斯分类器。

后验概率 在观测到样本 x 后，样本属于类别 ω_i 的条件概率 $P(\omega_i | x)$ 。由贝叶斯公式，

$$P(\omega_i | x) = \frac{P(x | \omega_i)P(\omega_i)}{\sum_j P(x | \omega_j)P(\omega_j)}.$$

朴素贝叶斯分类器

在给定类别条件下假设各特征条件独立的贝叶斯分类器。其判别规则为

$$\hat{y} = \arg \max_c P(c) \prod_{j=1}^d P(x_j | c).$$

五、贝叶斯决策

练习 7: 五、贝叶斯决策. 假定对某一类人群进行疾病筛查，正常人群为 ω_1 ，患者为 ω_2 ，设正常和患者的先验概率为：

$$P(\omega_1) = 0.7, \quad P(\omega_2) = 0.3.$$

现有一位被检查者，其观测值为 x ，从类条件概率密度曲线上查得：

$$P(x | \omega_1) = 0.15, \quad P(x | \omega_2) = 0.45.$$

同时已知风险损失函数为：

$$\begin{pmatrix} \lambda_{11} & \lambda_{12} \\ \lambda_{21} & \lambda_{22} \end{pmatrix} = \begin{pmatrix} 0 & 5 \\ 1 & 0 \end{pmatrix}.$$

试对该被检查者用以下两种方式进行分类：(1) 用最小错误率的贝叶斯决策，并写出判别函数和决策方程；(2) 用最小风险的贝叶斯决策，并写出判别函数和决策方程。

先计算后验概率。未归一化后验为

$$P(x | \omega_1)P(\omega_1) = 0.15 \times 0.7 = 0.105, \quad P(x | \omega_2)P(\omega_2) = 0.45 \times 0.3 = 0.135.$$

归一化因子为 $P(x|\omega_1)P(\omega_1) + P(x|\omega_2)P(\omega_2) = 0.24$, 因此

$$P(\omega_1 | x) = 0.4375, \quad P(\omega_2 | x) = 0.5625.$$

(1) 最小错误率贝叶斯决策的判别函数可取

$$g_i(x) = P(x | \omega_i)P(\omega_i) \quad \text{或} \quad g_i(x) = P(\omega_i | x).$$

决策方程为

$$\hat{\omega} = \arg \max_i g_i(x).$$

本题中

$$g_1(x) = 0.105, \quad g_2(x) = 0.135,$$

因为 $g_2(x) > g_1(x)$, 所以按最小错误率判为 ω_2 , 即患者。

(2) 按贝叶斯决策中常用记号, 设 $\lambda_{ij} = \lambda(\alpha_i | \omega_j)$, 即行对应采取的决策, 列对应真实类别。风险判别函数可取

$$r_i(x) = R(\alpha_i | x) = \sum_j \lambda_{ij} P(\omega_j | x),$$

并选择风险较小的决策。损失矩阵是:

$$\begin{pmatrix} \lambda_{11} & \lambda_{12} \\ \lambda_{21} & \lambda_{22} \end{pmatrix} = \begin{pmatrix} 0 & 5 \\ 1 & 0 \end{pmatrix}$$

通常理解: λ_{ij} 表示“把样本判为 ω_i , 但真实类别是 ω_j ”的损失。两个决策风险为

$$R(\alpha_1 | x) = 0 \cdot P(\omega_1 | x) + 5P(\omega_2 | x) = 2.8125,$$

$$R(\alpha_2 | x) = 1 \cdot P(\omega_1 | x) + 0 \cdot P(\omega_2 | x) = 0.4375.$$

最小风险决策方程为

$$\hat{\alpha} = \arg \min_i R(\alpha_i | x).$$

因为 $R(\alpha_2 | x) < R(\alpha_1 | x)$, 所以按最小风险判为 ω_2 , 即患者。等价地, 当

$$5P(\omega_2 | x) < P(\omega_1 | x)$$

时判为正常, 否则判为患者; 本题不满足该不等式。

六、朴素贝叶斯分类器

练习 8: 六、朴素贝叶斯分类器. 请从下列样本中构造一个朴素贝叶斯分类器, 确定样本 $x = (2020, P)^T$ 的类别。样本 x 具有二维特征属性, 取值分别为 $\{2019, 2020, 2021\}$ 和 $\{P, N, T\}$, y 为监督标记 $\{-1, 1\}$, 代表正类和反类。

i	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
x_1	2019	2019	2019	2019	2019	2020	2020	2020	2020	2020	2021	2021	2021	2021	2021
x_2	P	N	N	P	P	P	N	N	T	T	T	N	N	T	T
y	-1	-1	1	1	-1	-1	-1	1	1	1	1	1	1	1	-1

由样本表统计得

$$P(y=1) = \frac{9}{15} = \frac{3}{5}, \quad P(y=-1) = \frac{6}{15} = \frac{2}{5}.$$

题目未要求平滑，朴素贝叶斯分类器取

$$\hat{y} = \arg \max_{c \in \{-1, 1\}} P(y=c)P(x_1=2020 | y=c)P(x_2=P | y=c).$$

各条件概率为

$$\begin{aligned} P(x_1=2020 | y=1) &= \frac{3}{9} = \frac{1}{3}, & P(x_2=P | y=1) &= \frac{1}{9}, \\ P(x_1=2020 | y=-1) &= \frac{2}{6} = \frac{1}{3}, & P(x_2=P | y=-1) &= \frac{3}{6} = \frac{1}{2}. \end{aligned}$$

于是

$$\begin{aligned} P(y=1) \prod_j P(x_j | y=1) &= \frac{3}{5} \cdot \frac{1}{3} \cdot \frac{1}{9} = \frac{1}{45}, \\ P(y=-1) \prod_j P(x_j | y=-1) &= \frac{2}{5} \cdot \frac{1}{3} \cdot \frac{1}{2} = \frac{1}{15}. \end{aligned}$$

由于 $\frac{1}{15} > \frac{1}{45}$ ，故

$$\hat{y} = -1.$$

因此样本 $x = (2020, P)^T$ 的预测类别为标签 -1 所对应的类别。

4. 第 4 章：线性模型

一、名词解释

练习 9：名词解释。 解释以下概念：基函数、联系函数、支持向量 (SV)、梯度下降法、交叉熵、代价函数。

基函数 将原始输入映射为新特征的函数，如 $\phi_j(x)$ 。线性模型可写为 $f(x) = \sum_j w_j \phi_j(x)$ 。

联系函数 广义线性模型中连接条件均值与线性预测项的函数，如逻辑回归中的 logit 函数。

支持向量 SVM 中位于间隔边界上或违反间隔约束、对分类超平面起决定作用的训练样本。

梯度下降法 沿目标函数负梯度方向迭代更新参数的方法： $\theta \leftarrow \theta - \eta \nabla_{\theta} J(\theta)$ 。

交叉熵 衡量真实分布 p 与预测分布 q 差异的损失， $H(p, q) = -\sum_i p_i \log q_i$ 。

代价函数 学习算法需要最小化的总体目标函数，通常由经验损失和正则化项组成。

三、一对多判别边界

练习 10：一对多判别边界。 假设三个 $\omega_1, \omega_2, \omega_3$ 判别函数为：

$$\begin{cases} g_1(x) = -x_1 - x_2 + 5 \\ g_2(x) = -x_1 + 3 \\ g_3(x) = -x_1 + x_2 \end{cases}$$

请画图给出一对多情况下的判别边界，以及三个类别的判别区域，并判断样本 $(1, 3)$ 及 $(4, 5)$ 的类别，如果不能确定其类别，请说明原因。

三个边界分别为

$$g_1(x) = 0 : x_1 + x_2 = 5, \quad g_2(x) = 0 : x_1 = 3, \quad g_3(x) = 0 : x_2 = x_1.$$

一对多分类中，若恰有一个判别函数为正，则判为对应类别；若多个为正或全为负，则类别不能唯一确定。因此三个确定分类区域为

$$\omega_1 : g_1 > 0, g_2 < 0, g_3 < 0,$$

$$\omega_2 : g_2 > 0, g_1 < 0, g_3 < 0,$$

$$\omega_3 : g_3 > 0, g_1 < 0, g_2 < 0.$$

对样本 (1, 3),

$$(g_1, g_2, g_3) = (1, 2, 2),$$

三个分类器均给出正类，发生冲突，类别不能确定。对样本 (4, 5),

$$(g_1, g_2, g_3) = (-4, -1, 1),$$

仅 $g_3 > 0$ ，故判为 ω_3 。




图 2: 一对多判别边界与确定分类区域

四、LDA 投影

练习 11: LDA 投影. 计算题:

- (1) 假设 LDA 最佳投影直线确定为 $5x_1 - 2x_2 + 1 = 0$ 。试求向量 $\begin{pmatrix} 2 \\ 0 \end{pmatrix}$ 、 $\begin{pmatrix} -1 \\ -7 \end{pmatrix}$ 在该直线的 LDA 投影;
- (2) 推导样本在直线 w 上投影点的协方差为 $w^T \Sigma_0 w$ 。

- (1) 直线为 $5x_1 - 2x_2 + 1 = 0$ ，法向量 $n = (5, -2)^T$ 。点 x 到该直线的正交投影为

$$x' = x - \frac{n^T x + 1}{\|n\|^2} n, \quad \|n\|^2 = 29.$$

对 $x = (2, 0)^T$,

$$x' = (2, 0)^T - \frac{11}{29}(5, -2)^T = \left(\frac{3}{29}, \frac{22}{29}\right)^T.$$

对 $x = (-1, -7)^T$,

$$x' = (-1, -7)^T - \frac{10}{29}(5, -2)^T = \left(-\frac{79}{29}, -\frac{183}{29}\right)^T.$$

(2) 设样本 x 的均值为 μ , 协方差为 $\Sigma_0 = E[(x - \mu)(x - \mu)^T]$ 。在方向 w 上的一维投影为 $z = w^T x$, 则

$$\text{Var}(z) = E[(w^T x - w^T \mu)^2] = E[w^T (x - \mu)(x - \mu)^T w] = w^T \Sigma_0 w.$$

七、交叉熵损失

练习 12: 交叉熵损失. 已知 10 个二分类样本的分类标签依次为 (0, 1, 1, 1, 0, 0, 0, 0, 1, 0), 其中 1 为正类标签, 0 为负类标签。分类器预测结果如下:

样本	1	2	3	4	5	6	7	8	9	10
正类概率	0.1	0.88	0.92	0.65	0.2	0.3	0.4	0.1	0.85	0.1
负类概率	0.9	0.12	0.08	0.35	0.8	0.7	0.6	0.9	0.15	0.9

请计算这 10 个样本的交叉熵损失。

交叉熵只需要取每个样本“真实类别对应的预测概率”。

二分类交叉熵取自然对数:

$$L = - \sum_{i=1}^{10} [y_i \log p_i + (1 - y_i) \log(1 - p_i)].$$

10 个样本真实类别对应概率分别是:

$$0.9, 0.88, 0.92, 0.65, 0.8, 0.7, 0.6, 0.9, 0.85, 0.9$$

逐项相加得

$$\begin{aligned} L &= -(\ln 0.9 + \ln 0.88 + \ln 0.92 + \ln 0.65 + \ln 0.8 + \ln 0.7 + \ln 0.6 + \ln 0.9 + \ln 0.85 + \ln 0.9) \\ &= 2.2112. \end{aligned}$$

若按样本平均, 则

$$\bar{L} = \frac{L}{10} = 0.2211.$$

5. 第 5 章: 决策树

一、名词解释

练习 13: 名词解释. 解释以下概念: 熵和条件熵、信息增益、基尼指数。

熵和条件熵 熵衡量随机变量不确定性: $H(Y) = -\sum_k p_k \log_2 p_k$ 。条件熵衡量给定 X 后 Y 的平均不确定性: $H(Y | X) = \sum_x P(X = x)H(Y | X = x)$ 。

信息增益 用属性 A 划分数据集 D 后不确定性的减少量:

$$\text{Gain}(D, A) = H(D) - H(D | A).$$

ID3 每次选择信息增益最大的属性。

基尼指数 CART 分类树常用的不纯度指标：

$$Gini(D) = 1 - \sum_k p_k^2.$$

基尼指数越小，节点越纯。

四、最小二乘回归树

练习 14: 最小二乘回归树. 根据下列样本，生成一个深度 `depth=3` 的最小二乘回归树并作图。

x	1	2	3	4	5	6	7	8	9	10
y	4.5	4.75	4.91	5.34	5.8	7.05	7.9	8.23	8.7	9.5

回归树的思想是：每次找一个切分点 s ，把样本分成两个区域：

$$R_1 = \{x | x \leq s\}$$

$$R_2 = \{x | x > s\}$$

每个区域的预测值取该区域内 y 的均值：

$$c_1 = \frac{1}{|R_1|} \sum_{x_i \in R_1} y_i$$

$$c_2 = \frac{1}{|R_2|} \sum_{x_i \in R_2} y_i$$

然后选择使平方误差最小的切分点：

$$\min_s \left[\sum_{x_i \in R_1} (y_i - c_1)^2 + \sum_{x_i \in R_2} (y_i - c_2)^2 \right]$$

采用 CART 最小二乘准则，对每个候选切分点 s 计算

$$\sum_{x_i \leq s} (y_i - \bar{y}_L)^2 + \sum_{x_i > s} (y_i - \bar{y}_R)^2.$$

将根节点深度记为 0，取 `max_depth=3`。因为 x 是从 1 到 10，所以候选切分点一般取相邻 x 的中点：

$$1.5, 2.5, 3.5, \dots, 9.5$$

根节点候选切分中， $s = 5.5$ 的误差最小，误差为 4.3827，因此先切分为 $x \leq 5.5$ 与 $x > 5.5$ 。

左边 $x = 1, 2, 3, 4, 5$ ，对应 y 的均值为：

$$c_L = \frac{4.5 + 4.75 + 4.91 + 5.34 + 5.8}{5} = 5.06$$

右边 $x = 6, 7, 8, 9, 10$ ，对应 y 的均值为：

$$c_R = \frac{7.05 + 7.9 + 8.23 + 8.7 + 9.5}{5} = 8.276$$

继续递归切分得到

$$x \leq 5.5: \quad x \leq 3.5, \quad (x \leq 1.5), \quad (x \leq 4.5),$$

$$x > 5.5: \quad x \leq 8.5, \quad (x \leq 6.5), \quad (x \leq 9.5).$$

最终叶节点预测值为各叶节点内样本 y 的均值：

区间	预测值
$x \leq 1.5$	4.50
$1.5 < x \leq 3.5$	4.83
$3.5 < x \leq 4.5$	5.34
$4.5 < x \leq 5.5$	5.80
$5.5 < x \leq 6.5$	7.05
$6.5 < x \leq 8.5$	8.065
$8.5 < x \leq 9.5$	8.70
$x > 9.5$	9.50




图 3: 分段常数预测拟合




图 4: 深度为 3 的最小二乘回归树

五、ID3 与 CART 决策树

练习 15: ID3 与 CART 决策树. 计算题：对下表分别用 ID3 和 CART 算法生成决策树（要求写出详细的计算步骤）。

ID	年龄	有工作	有自己的房子	信贷情况	类别
1	青年	否	否	一般	否
2	青年	否	否	好	否
3	青年	是	否	好	是
4	青年	是	是	好	是
5	青年	是	是	非常好	是
6	青年	是	是	一般	是
7	青年	否	否	一般	否
8	中年	否	否	一般	否
9	中年	否	否	好	否
10	中年	是	是	好	是
11	中年	否	是	非常好	是
12	中年	否	是	非常好	是
13	中年	是	是	好	是
14	老年	否	是	非常好	是
15	老年	否	是	好	是
16	老年	是	否	好	是
17	老年	是	否	非常好	是
18	老年	否	否	一般	否

数据集中正例“是”（记作 $y = 1$ ）有 12 个，反例“否”（记作 $y = 0$ ）有 6 个，总计 $|D| = 18$ 。

一、ID3 决策树

信息熵的定义为 $H(D) = -\sum_k p_k \log_2 p_k$ 。首先计算根节点的总熵：

$$\begin{aligned}
 H(D) &= -\frac{12}{18} \log_2 \frac{12}{18} - \frac{6}{18} \log_2 \frac{6}{18} \\
 &= -\frac{2}{3} \log_2 \frac{2}{3} - \frac{1}{3} \log_2 \frac{1}{3} \\
 &= \frac{2}{3} \times 0.5850 + \frac{1}{3} \times 1.5850 \\
 &= 0.3900 + 0.5283 = 0.9183
 \end{aligned}$$

下面以属性“年龄”为例，说明条件熵与信息增益的计算过程。年龄有三个取值——青年、中年、老年，各子集的样本分布为

年龄	样本 ID	样本数	是	否	子集熵 H
青年	1-7	7	4	3	$-\frac{4}{7} \log_2 \frac{4}{7} - \frac{3}{7} \log_2 \frac{3}{7} = 0.9853$
中年	8-13	6	4	2	$-\frac{4}{6} \log_2 \frac{4}{6} - \frac{2}{6} \log_2 \frac{2}{6} = 0.9183$
老年	14-18	5	4	1	$-\frac{4}{5} \log_2 \frac{4}{5} - \frac{1}{5} \log_2 \frac{1}{5} = 0.7219$

先按 p_k 分别计算每个子集的熵（上表最右列）。然后将各子集熵以样本占比为权重求和，得到条件熵：

$$\begin{aligned}
 H(D|\text{年龄}) &= \frac{7}{18} \times 0.9853 + \frac{6}{18} \times 0.9183 + \frac{5}{18} \times 0.7219 \\
 &= 0.3832 + 0.3061 + 0.2005 = 0.8898
 \end{aligned}$$

信息增益为划分前后熵的差值：

$$Gain(D, \text{年龄}) = H(D) - H(D|\text{年龄}) = 0.9183 - 0.8898 = 0.0285.$$

其余三个属性按完全相同的步骤计算，结果汇总如下：

特征	条件熵 $H(D A)$	信息增益 $Gain(D, A)$
年龄	0.8898	0.0285
有工作	0.5394	0.3789
有自己的房子	0.4591	0.4591
信贷情况	0.5611	0.3572

信息增益最大者为“有自己的房子”，故 ID3 根节点选择该属性。当“有自己的房子 = 是”时，9 个样本全部为“是”，直接为叶节点。当“有自己的房子 = 否”时，子集含 6 个“否”、3 个“是”，熵仍为 0.9183。在该子集上继续计算剩余属性的信息增益：

属性	$Gain$
年龄	0.2516
有工作	0.9183
信贷情况	0.4739

故继续按“有工作”划分；“有工作 = 否”的样本全为“否”，“有工作 = 是”的样本全为“是”。ID3 决策树为

若有自己的房子 = 是，则类别 = 是；
 若有自己的房子 = 否且有工作 = 是，则类别 = 是；
 若有自己的房子 = 否且有工作 = 否，则类别 = 否。

二、CART 决策树

CART 算法使用基尼指数 $Gini(D) = 1 - \sum_k p_k^2$ 。根节点

$$Gini(D) = 1 - \left(\frac{12}{18}\right)^2 - \left(\frac{6}{18}\right)^2 = \frac{4}{9} = 0.4444.$$

下面以属性“年龄”为例，说明多值离散属性在 CART 中如何求最优二分切分。年龄有三种取值，共有三种可能的二分方式：

切分方式	左分支 Gini	右分支 Gini
{青年} vs {中年, 老年}	$1 - \left(\frac{4}{7}\right)^2 - \left(\frac{3}{7}\right)^2 = \frac{24}{49} \approx 0.4898$	$1 - \left(\frac{8}{11}\right)^2 - \left(\frac{3}{11}\right)^2 = \frac{48}{121} \approx 0.3967$
{中年} vs {青年, 老年}	$1 - \left(\frac{4}{6}\right)^2 - \left(\frac{2}{6}\right)^2 = \frac{4}{9} = 0.4444$	$1 - \left(\frac{8}{12}\right)^2 - \left(\frac{4}{12}\right)^2 = \frac{4}{9} = 0.4444$
{老年} vs {青年, 中年}	$1 - \left(\frac{4}{5}\right)^2 - \left(\frac{1}{5}\right)^2 = \frac{8}{25} = 0.3200$	$1 - \left(\frac{8}{13}\right)^2 - \left(\frac{5}{13}\right)^2 = \frac{80}{169} \approx 0.4734$

对每种切分，以左右分支的样本占比为权重计算加权基尼指数。例如第三种切分：

$$\frac{5}{18} \times 0.3200 + \frac{13}{18} \times 0.4734 = 0.0889 + 0.3419 = 0.4308.$$

三种切分的加权基尼依次为 0.4329、0.4444、0.4308，取最小者 0.4308 作为属性“年龄”的得分。

其余属性按同样方法（二值属性只有一种切分，无需枚举）计算，各属性最小加权基尼汇总如下：

属性	最小加权 $Gini$
年龄	0.4308
有工作	0.2667
有自己的房子	0.2222
信贷情况	0.2769

最小者仍为“有自己的房子” (0.2222)，切分为“否”与“是”。“有自己的房子 = 是”分支纯度为 0。在“有自己的房子 = 否”子集上，继续按“有工作”切分时加权基尼指数为 0，两个分支均纯。因此 CART 树与上面的 ID3 树结构一致。

6. 第 6 章：集成学习

一、名词解释

练习 16：名词解释。解释概念：基学习器。

基学习器 集成学习中被组合的单个学习器，也称个体学习器或弱学习器。多个基学习器通过投票、加权投票、平均或堆叠等方式形成集成模型。

二、AdaBoost 权重迭代关系

练习 17：AdaBoost 权重迭代关系。复习 AdaBoost 算法，试推导样本 x_i 第 t 轮的权重与第 $t+1$ 轮权重存在如下迭代关系。其中 e_t 为第 t 轮分类器的错误率：

$$w_{t+1,i} = \begin{cases} \frac{w_{ti}}{2(1-e_t)}, & \text{分类正确} \\ \frac{w_{ti}}{2e_t}, & \text{分类不正确} \end{cases}$$

AdaBoost 的算法流程

初始化样本权重：

$$w_{1i} = \frac{1}{N}, \quad i = 1, 2, \dots, N$$

第 t 轮训练弱分类器 $h_t(x)$ 。

计算加权错误率：

$$e_t = \sum_{i=1}^N w_{ti} I(h_t(x_i) \neq y_i)$$

计算弱分类器权重：

$$\alpha_t = \frac{1}{2} \ln \frac{1-e_t}{e_t}$$

更新样本权重：

$$w_{t+1,i} = \frac{w_{ti} \exp(-\alpha_t y_i h_t(x_i))}{Z_t}$$

其中 Z_t 是归一化因子，保证所有样本权重之和为 1。

最终强分类器：

$$H(x) = \text{sign} \left(\sum_{t=1}^T \alpha_t h_t(x) \right)$$

AdaBoost 第 t 轮样本权重更新为

$$w_{t+1,i} = \frac{w_{t,i} \exp(-\alpha_t y_i h_t(x_i))}{Z_t}, \quad \alpha_t = \frac{1}{2} \ln \frac{1-e_t}{e_t}.$$

其中 $y_i h_t(x_i) = 1$ 表示分类正确， $y_i h_t(x_i) = -1$ 表示分类错误。归一化因子为

$$Z_t = (1-e_t)e^{-\alpha_t} + e_t e^{\alpha_t} = 2\sqrt{e_t(1-e_t)}.$$

若分类正确，

$$w_{t+1,i} = \frac{w_{t,i} e^{-\alpha_t}}{Z_t} = \frac{w_{t,i}}{2(1-e_t)}.$$

若分类错误,

$$w_{t+1,i} = \frac{w_{t,i}e^{\alpha_t}}{Z_t} = \frac{w_{t,i}}{2e_t}.$$


这正是题中给出的迭代关系。

三、AdaBoost 强分类过程

练习 18: AdaBoost 强分类过程. 给定如图表所示的训练样本, 弱学习器采用平行于坐标轴的直线 h_1 、 h_2 和 h_3 , 请用 AdaBoost 算法实现强分类过程。

$$h_1 = \begin{cases} 1, & X_1 < 2.5 \\ -1, & X_1 > 2.5 \end{cases}, \quad h_2 = \begin{cases} 1, & X_1 < 8.5 \\ -1, & X_1 > 8.5 \end{cases}, \quad h_3 = \begin{cases} 1, & X_2 > 6.5 \\ -1, & X_2 < 6.5 \end{cases}$$

样本序号	1	2	3	4	5	6	7	8	9	10
样本点 X	(1,5)	(2,2)	(3,1)	(4,6)	(6,8)	(6,5)	(7,9)	(8,7)	(9,8)	(10,2)
类别 Y	1	1	-1	-1	1	-1	1	1	-1	-1



初始权重 $D_1(i) = 0.1$ 。三个弱分类器第一轮错误率均为 0.3, 按题目给出的顺序选 h_1 。

第一轮 ($t = 1, h_1$)。 h_1 以 $X_1 = 2.5$ 为界 ($X_1 < 2.5 \rightarrow +1, X_1 > 2.5 \rightarrow -1$), 错分样本为 $\{5, 7, 8\}$ 。

$$e_1 = 3 \times 0.1 = \frac{3}{10}, \quad \alpha_1 = \frac{1}{2} \ln \frac{7}{3} \approx 0.4236.$$

更新权重。记 $e^{-\alpha_1} = \sqrt{3/7}$, $e^{\alpha_1} = \sqrt{7/3}$, 归一化因子 $Z_1 = 7 \cdot 0.1 \sqrt{3/7} + 3 \cdot 0.1 \sqrt{7/3} = 0.2\sqrt{21}$, 得

$$D_2(\text{正确}) = \frac{1}{14} \approx 0.0714, \quad D_2(\text{错分}) = \frac{1}{6} \approx 0.1667.$$

第二轮 ($t = 2, h_2$)。 h_2 以 $X_1 = 8.5$ 为界 ($X_1 < 8.5 \rightarrow +1, X_1 > 8.5 \rightarrow -1$), 错分样本为 $\{3, 4, 6\}$ (权重均为 $1/14$)。

$$e_2 = 3 \times \frac{1}{14} = \frac{3}{14}, \quad \alpha_2 = \frac{1}{2} \ln \frac{11}{3} \approx 0.6496.$$

更新权重。 $e^{-\alpha_2} = \sqrt{3/11}$, $e^{\alpha_2} = \sqrt{11/3}$, 归一化因子 $Z_2 = \frac{11}{14} \sqrt{\frac{3}{11}} + \frac{3}{14} \sqrt{\frac{11}{3}} = \frac{\sqrt{33}}{7}$ 。按上一轮是否错

分归类：

$$\text{两轮均正确 } (i = 1, 2, 9, 10) : D_3 = \frac{1}{22} \approx 0.0455,$$

$$\text{仅首轮错 } (i = 5, 7, 8) : D_3 = \frac{7}{66} \approx 0.1061,$$

$$\text{仅本轮错 } (i = 3, 4, 6) : D_3 = \frac{1}{6} \approx 0.1667.$$

第三轮 ($t = 3, h_3$)。 h_3 以 $X_2 = 6.5$ 为界 ($X_2 > 6.5 \rightarrow +1, X_2 < 6.5 \rightarrow -1$)，错分样本为 $\{1, 2, 9\}$ (权重均为 $1/22$)。

$$e_3 = 3 \times \frac{1}{22} = \frac{3}{22}, \quad \alpha_3 = \frac{1}{2} \ln \frac{19}{3} \approx 0.9229.$$

三轮迭代的汇总结果如下：

t	h_t	错分样本	e_t	α_t
1	h_1	5, 7, 8	3/10	$\frac{1}{2} \ln \frac{7}{3} = 0.4236$
2	h_2	3, 4, 6	3/14	$\frac{1}{2} \ln \frac{11}{3} = 0.6496$
3	h_3	1, 2, 9	3/22	$\frac{1}{2} \ln \frac{19}{3} = 0.9229$

因此强分类器为

$$H(x) = \text{sign}(0.4236h_1(x) + 0.6496h_2(x) + 0.9229h_3(x)).$$

对 10 个训练样本，强分类器的加权输出符号为

样本	真实 Y	最终得分 $F(x)$	强分类器结果
1	1	0.1504	1
2	1	0.1504	1
3	-1	-0.6969	-1
4	-1	-0.6969	-1
5	1	1.1489	1
6	-1	-0.6969	-1
7	1	1.1489	1
8	1	1.1489	1
9	-1	-0.1504	-1
10	-1	-1.9962	-1

与给定类别完全一致。

7. 第 7 章：维度归约

一、名词解释

练习 19: 名词解释. 解释概念：测地线 (geodesic) 距离。

测地线距离 在流形或曲面上沿该流形可行路径连接两点的最短路径长度。与欧氏距离不同，测地线距离考虑数据所在流形的弯曲结构。

四、正交投影矩阵


练习 20: 正交投影矩阵. 降维分析中涉及投影的变换矩阵通常要求是正交的。请问：

- (1) 正交投影矩阵相对于非正交投影矩阵用于降维的优点是什么？
- (2) 为什么在 PCA 中变换矩阵一定是正交的？

- (1) 正交投影矩阵的列向量相互正交且通常归一化，优点是投影后的坐标不冗余，不会人为引入斜交坐标造成的尺度耦合；长度、角度和方差解释更清楚，数值计算也更稳定。非正交投影可能把不同方向的信息混在一起，使投影坐标相关，解释性和重构分析都较差。
- (2) PCA 的投影方向来自样本协方差矩阵的特征向量。协方差矩阵是实对称矩阵，不同特征值对应的特征向量正交；重特征值对应的特征子空间也可以选取一组正交规范基。因此 PCA 的变换矩阵可取为正交矩阵。

五、PCA 与 LDA 投影方向

练习 21: PCA 与 LDA 投影方向. 如图给出了一组数据，使用 LDA 投影比 PCA 投影有更好的投影方向。参照这个图，绘制一个二维数据集示例，让 PCA 和 LDA 找到相同的好方向。另绘制一个数据集，让 PCA 和 LDA 都找不到一个好的投影方向。



当两类样本的均值差方向也是总方差最大的方向时，PCA 和 LDA 会找到相同的好方向。例如两团数据左右分离，主要差异在 x 轴方向。相反，XOR 型数据中两类均值相同，类别信息不是任何单一线性投影能表达的；PCA 只看总体方差，LDA 的类均值差又为零，两者都找不到好的投影方向。




图 5: PCA 与 LDA 投影方向示例

六、PCA 主分量与方差贡献率

练习 22: PCA 主分量与方差贡献率. 计算题：用 PCA 方法计算这 6 个二维样本数据的一维 PCA 主分量，并计算该主分量的方差贡献率：

$$\begin{pmatrix} 2 & 3 & 3 & 4 & 5 & 7 \\ 2 & 4 & 5 & 5 & 6 & 8 \end{pmatrix}$$

注意：该样本未中心化！

计算样本均值。

6 个样本的均值向量为

$$\mu = \frac{1}{6} \sum_{i=1}^6 x_i = \left(\frac{2+3+3+4+5+7}{6}, \frac{2+4+5+5+6+8}{6} \right)^T = (4, 5)^T.$$

中心化样本数据。

将每个样本减去均值，得到中心化后的样本矩阵

$$X_c = X - \mu \mathbf{1}^T = \begin{pmatrix} -2 & -1 & -1 & 0 & 1 & 3 \\ -3 & -1 & 0 & 0 & 1 & 3 \end{pmatrix}.$$

计算协方差矩阵。

协方差矩阵定义为 $\Sigma = \frac{1}{n} X_c X_c^T$ 。先计算 $X_c X_c^T$ ：

$$X_c X_c^T = \begin{pmatrix} 16 & 17 \\ 17 & 20 \end{pmatrix}.$$

因此协方差矩阵为

$$\Sigma = \frac{1}{6} \begin{pmatrix} 16 & 17 \\ 17 & 20 \end{pmatrix} = \begin{pmatrix} \frac{8}{3} & \frac{17}{6} \\ \frac{17}{6} & \frac{10}{3} \end{pmatrix} \approx \begin{pmatrix} 2.6667 & 2.8333 \\ 2.8333 & 3.3333 \end{pmatrix}.$$

求解特征值。

特征方程为 $\det(\Sigma - \lambda I) = 0$ ，即

$$\left(\frac{8}{3} - \lambda \right) \left(\frac{10}{3} - \lambda \right) - \left(\frac{17}{6} \right)^2 = 0.$$

解得

$$\lambda = \frac{18 \pm \sqrt{293}}{6}.$$

数值结果为

$$\lambda_1 = \frac{18 + \sqrt{293}}{6} \approx 5.8529, \quad \lambda_2 = \frac{18 - \sqrt{293}}{6} \approx 0.1471.$$

求解主分量方向（最大特征值对应的特征向量）。

将 $\lambda_1 \approx 5.8529$ 代入 $(\Sigma - \lambda_1 I)u = 0$ ，取第一个方程

$$\left(\frac{8}{3} - \lambda_1 \right) u_1 + \frac{17}{6} u_2 = 0 \quad \Rightarrow \quad u_1 = \frac{17/6}{\lambda_1 - 8/3} u_2 \approx 0.8893 u_2.$$

归一化条件 $u_1^2 + u_2^2 = 1$ 给出

$$(0.8893^2 + 1) u_2^2 = 1 \quad \Rightarrow \quad u_2 = \frac{1}{\sqrt{1 + 0.8893^2}} \approx 0.7473, \quad u_1 \approx 0.6645.$$

因此一维 PCA 主分量方向为

$$u_1 = \begin{pmatrix} 0.6645 \\ 0.7473 \end{pmatrix}.$$

计算投影坐标。

将中心化样本投影到主分量方向上，得到一维坐标

$$z = X_c^T u_1 = \begin{pmatrix} -2 \times 0.6645 + (-3) \times 0.7473 \\ -1 \times 0.6645 + (-1) \times 0.7473 \\ -1 \times 0.6645 + 0 \times 0.7473 \\ 0 \times 0.6645 + 0 \times 0.7473 \\ 1 \times 0.6645 + 1 \times 0.7473 \\ 3 \times 0.6645 + 3 \times 0.7473 \end{pmatrix} = \begin{pmatrix} -3.5709 \\ -1.4118 \\ -0.6645 \\ 0 \\ 1.4118 \\ 4.2354 \end{pmatrix}.$$

计算方差贡献率。

方差贡献率表示主分量解释的方差占总方差的比例：

$$\text{方差贡献率} = \frac{\lambda_1}{\lambda_1 + \lambda_2} = \frac{5.8529}{5.8529 + 0.1471} = \frac{5.8529}{6} \approx 0.9755.$$

即第一主分量解释了约 97.55% 的总方差，说明用一维主分量就能很好地表示原始二维数据。

8. 第 8 章：聚类

一、名词解释

练习 23：名词解释。 解释以下概念：Jaccard 系数、密度可达。

DBSCAN

Density-Based Spatial Clustering of Applications with Noise, 基于密度的带噪声应用空间聚类

Jaccard 系数

用于衡量两个集合相似度：

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}.$$

在二值特征中，它只关注两个样本同时取 1 与至少一个取 1 的特征。

密度可达 在 DBSCAN 中，若存在样本链 $p_1, \dots, p_n$ ，其中 $p_1 = q$ 、 $p_n = p$ ，且每个 p_{i+1} 都从核心点 p_i 直接密度可达，则称 p 从 q 密度可达。

二、k-means 与 kNN

练习 24：k-means 与 kNN。 k-means 算法与 kNN 方法的 k 分别指什么？这两个方法的主要区别是什么？

k-means 中的 k 表示要划分出的簇数；kNN 中的 k 表示预测时参与投票或平均的最近邻样本个数。k-means 是无监督聚类算法，没有训练标签，目标是最小化簇内平方误差；kNN 是监督学习方法，需要带标签训练样本，预测时根据邻居标签决定输出。k-means 会学习簇中心，kNN 通常是惰性学习，预测阶段才进行距离搜索。

四、k-means 聚类

练习 25：k-means 聚类。 给定含有 5 个样本的集合：

$$X = \begin{bmatrix} 0 & 0 & 1 & 5 & 5 \\ 2 & 0 & 0 & 0 & 2 \end{bmatrix}$$

试用 k-means 聚类算法将样本聚到两个类中 ($k=2$)，选 $(0,0)^T$ 、 $(5,2)^T$ 为初始质心。

样本与初始质心。

从矩阵 X 中读出 5 个样本（按列）：

$$x_1 = (0, 2)^T, \quad x_2 = (0, 0)^T, \quad x_3 = (1, 0)^T, \quad x_4 = (5, 0)^T, \quad x_5 = (5, 2)^T.$$

初始质心为

$$\mu_1^{(0)} = (0, 0)^T, \quad \mu_2^{(0)} = (5, 2)^T.$$

第一轮：分配样本到最近质心。

计算每个样本到两个质心的欧氏距离：

样本	坐标	$d(x_i, \mu_1^{(0)})$	$d(x_i, \mu_2^{(0)})$	分配结果
x_1	$(0, 2)^T$	$\sqrt{0^2 + 2^2} = 2$	$\sqrt{5^2 + 0^2} = 5$	C_1
x_2	$(0, 0)^T$	$\sqrt{0^2 + 0^2} = 0$	$\sqrt{5^2 + 2^2} = \sqrt{29}$	C_1
x_3	$(1, 0)^T$	$\sqrt{1^2 + 0^2} = 1$	$\sqrt{4^2 + 2^2} = 2\sqrt{5}$	C_1
x_4	$(5, 0)^T$	$\sqrt{5^2 + 0^2} = 5$	$\sqrt{0^2 + 2^2} = 2$	C_2
x_5	$(5, 2)^T$	$\sqrt{5^2 + 2^2} = \sqrt{29}$	$\sqrt{0^2 + 0^2} = 0$	C_2

分配结果：

$$C_1 = \{x_1, x_2, x_3\} = \{(0, 2)^T, (0, 0)^T, (1, 0)^T\}, \quad C_2 = \{x_4, x_5\} = \{(5, 0)^T, (5, 2)^T\}.$$

第一轮：更新质心。

新质心为各簇样本的均值：

$$\mu_1^{(1)} = \frac{1}{3} [(0, 2)^T + (0, 0)^T + (1, 0)^T] = \left(\frac{0+0+1}{3}, \frac{2+0+0}{3} \right)^T = \left(\frac{1}{3}, \frac{2}{3} \right)^T,$$

$$\mu_2^{(1)} = \frac{1}{2} [(5, 0)^T + (5, 2)^T] = \left(\frac{5+5}{2}, \frac{0+2}{2} \right)^T = (5, 1)^T.$$

第二轮：用新质心重新分配。

样本	坐标	$d(x_i, \mu_1^{(1)})$	$d(x_i, \mu_2^{(1)})$	分配结果
x_1	$(0, 2)^T$	$\sqrt{(0 - \frac{1}{3})^2 + (2 - \frac{2}{3})^2} = \frac{\sqrt{17}}{3}$	$\sqrt{(0 - 5)^2 + (2 - 1)^2} = \sqrt{26}$	C_1
x_2	$(0, 0)^T$	$\sqrt{(0 - \frac{1}{3})^2 + (0 - \frac{2}{3})^2} = \frac{\sqrt{5}}{3}$	$\sqrt{(0 - 5)^2 + (0 - 1)^2} = \sqrt{26}$	C_1
x_3	$(1, 0)^T$	$\sqrt{(1 - \frac{1}{3})^2 + (0 - \frac{2}{3})^2} = \frac{2\sqrt{2}}{3}$	$\sqrt{(1 - 5)^2 + (0 - 1)^2} = \sqrt{17}$	C_1
x_4	$(5, 0)^T$	$\sqrt{(5 - \frac{1}{3})^2 + (0 - \frac{2}{3})^2} = \frac{10\sqrt{2}}{3}$	$\sqrt{(5 - 5)^2 + (0 - 1)^2} = 1$	C_2
x_5	$(5, 2)^T$	$\sqrt{(5 - \frac{1}{3})^2 + (2 - \frac{2}{3})^2} = \frac{\sqrt{212}}{3}$	$\sqrt{(5 - 5)^2 + (2 - 1)^2} = 1$	C_2

分配结果与第一轮完全相同，质心不再变化，算法收敛。


最终聚类结果。

$$C_1 = \{(0, 2)^T, (0, 0)^T, (1, 0)^T\}, \quad \mu_1 = \left(\frac{1}{3}, \frac{2}{3} \right)^T,$$

$$C_2 = \{(5, 0)^T, (5, 2)^T\}, \quad \mu_2 = (5, 1)^T.$$

五、聚类算法选择

练习 26: 聚类算法选择. 对于下图的数据分类, 宜采用什么类聚类算法? 其基本原理是什么? 该算法中有哪两个重要参数? 这两个参数的取值对聚类的结果有什么影响?



DBSCAN 的几个概念

1. **核心点.** 如果一个点的 ϵ -邻域内点数不少于 MinPts , 它就是核心点。
2. **边界点.** 如果一个点本身不是核心点, 但落在某个核心点的 ϵ -邻域内, 它就是边界点。
3. **噪声点.** 如果一个点既不是核心点, 也不属于任何核心点的邻域, 它就是噪声点。
4. **密度直达.** 如果点 q 在核心点 p 的 ϵ -邻域内, 则称 q 由 p 密度直达。注意, 密度直达通常不是对称的, 因为 p 必须是核心点, 而 q 不一定是核心点。
5. **密度可达.** 如果存在一个点序列

$$p_1, p_2, \dots, p_n$$

其中 $p_1 = p$, $p_n = q$, 并且 p_{i+1} 由 p_i 密度直达, 那么称 q 从 p 密度可达。

图中簇呈非凸、弯曲形状, 并含有离群噪声点, 不适合用 k-means 这类偏向球形簇的算法。宜采用**密度聚类**, 典型算法为 DBSCAN。


DBSCAN 的基本思想是: 若某点 ϵ 邻域内样本数不少于 MinPts , 则该点为核心点; 从核心点出发, 把密度可达的点不断并入同一簇; 不能并入任何簇的点视为噪声。两个重要参数是邻域半径 ϵ 和最小邻域样本数 MinPts 。 ϵ 太小会把一个簇切碎并产生过多噪声, 太大则可能把相邻簇合并; MinPts 太小会把噪声误认为簇, 太大则会漏掉稀疏簇。

9. 第 9 章: 神经网络

一、TensorFlow 神经网络网页与二分类网络模型

练习 27: TensorFlow 神经网络网页与二分类网络模型. 请根据下列 TensorFlow 提供的一个神经网络学习网页, 及网页中给出的一个二分类网络模型, 回答:

- (1) 解释 ①-⑧ 的名词的含义;
- (2) 计算该二分类神经网络的参数数量。



(1) 图中 1-8 的含义如下。

编号	含义
1	训练集与测试集划分比例
2	批量大小，即一次参数更新使用的样本数
3	训练轮数 Epoch
4	学习率
5	激活函数
6	正则化方式
7	正则化系数
8	训练损失与测试损失，用于观察经验误差和泛化误差

(2) 图中网络结构为：输入层 2 个特征，6 个隐藏层（每层 7 个神经元），输出层 1 个神经元。

每一层的参数由”权重”和”偏置”组成。权重连接数 = 上一层神经元数 × 本层神经元数，每层偏置数 = 本层神经元数。

输入层 → 第 1 隐藏层： $2 \times 7 + 7 = 21$ 个参数。

隐藏层之间（共 5 组连接）：每组 $7 \times 7 + 7 = 56$ 个参数，合计 $5 \times 56 = 280$ 个参数。

第 6 隐藏层 → 输出层： $7 \times 1 + 1 = 8$ 个参数。

总参数数量为

$$21 + 280 + 8 = 309.$$

因此该网络共有 309 个可训练参数。

二、名词解释

练习 28: 名词解释. 解释以下概念：早停法（Early stopping）、暂退法（Dropout）、梯度弥散。

早停法 训练过程中监控验证集性能，当验证误差不再下降或开始上升时停止训练，以避免过拟合。


暂退法 Dropout, 在训练时以一定概率随机将部分神经元输出置零，使网络不能过度依赖某些局部特征，相当于一种正则化方法。

梯度弥散 深层网络反向传播时，梯度在多层链式相乘后逐渐变得很小，导致靠近输入层的参数更新缓慢甚至难以训练。

五、BP 神经网络一次迭代

练习 29: BP 神经网络一次迭代. 针对下列神经网络, 神经元激活函数为 $\tanh()$ 函数, 损失函数采用平方误差函数 (前带 $1/2$ 系数), 学习率 $\eta = 0.5$, 试做一次迭代:

- (1) 计算 h_1 、 h_2 、 o_1 、 o_2 的误差信号 δ ;
- (2) 更新参数 w_4 、 w_8 和 w_{01} 。



网络结构与参数。

采用图中权重连接关系: $w_1 : x_1 \rightarrow h_1$, $w_2 : x_1 \rightarrow h_2$, $w_3 : x_2 \rightarrow h_1$, $w_4 : x_2 \rightarrow h_2$; $w_5 : h_1 \rightarrow o_1$, $w_6 : h_1 \rightarrow o_2$, $w_7 : h_2 \rightarrow o_1$, $w_8 : h_2 \rightarrow o_2$ 。输入为 $x_1 = 0.05$ 、 $x_2 = 0.1$, 目标输出为 $y_1 = 0.01$ 、 $y_2 = 0.99$ 。激活函数为 $\tanh z$, 其导数为 $1 - \tanh^2 z$ 。

步骤一: 前向传播。

隐层输入与输出:

$$net_{h_1} = w_1 x_1 + w_3 x_2 + w_{01} = 0.15 \times 0.05 + 0.25 \times 0.1 + 0.35 = 0.3825,$$

$$h_1 = \tanh(0.3825) \approx 0.3649.$$

$$net_{h_2} = w_2 x_1 + w_4 x_2 + w_{02} = 0.2 \times 0.05 + 0.3 \times 0.1 + 0.35 = 0.39,$$

$$h_2 = \tanh(0.39) \approx 0.3714.$$

输出层输入与输出:

$$net_{o_1} = w_5 h_1 + w_7 h_2 + w_{03} = 0.4 \times 0.3649 + 0.5 \times 0.3714 + 0.6 \approx 0.9316,$$

$$o_1 = \tanh(0.9316) \approx 0.7314.$$

$$net_{o_2} = w_6 h_1 + w_8 h_2 + w_{04} = 0.45 \times 0.3649 + 0.55 \times 0.3714 + 0.6 \approx 0.9684,$$

$$o_2 = \tanh(0.9684) \approx 0.7480.$$

步骤二: 反向传播, 计算误差信号。

误差信号定义为 $\delta_j = -\frac{\partial E}{\partial net_j}$ 。以输出层神经元 o_1 为例, 由链式法则:

$$\frac{\partial E}{\partial net_{o_1}} = \frac{\partial E}{\partial o_1} \cdot \frac{\partial o_1}{\partial net_{o_1}}.$$

其中第一项由损失函数 $E = \frac{1}{2}(y_1 - o_1)^2$ 对 o_1 求导得

$$\frac{\partial E}{\partial o_1} = -(y_1 - o_1),$$

第二项由激活函数 $o_1 = \tanh(\text{net}_{o_1})$ 求导得

$$\frac{\partial o_1}{\partial \text{net}_{o_1}} = 1 - \tanh^2(\text{net}_{o_1}) = 1 - o_1^2.$$

因此输出层误差信号为

$$\delta_{o_1} = -\frac{\partial E}{\partial \text{net}_{o_1}} = (y_1 - o_1)(1 - o_1^2).$$

同理可得 $\delta_{o_2} = (y_2 - o_2)(1 - o_2^2)$ 。代入数值：

$$\delta_{o_1} = (0.01 - 0.7314)(1 - 0.7314^2) \approx -0.3355,$$

$$\delta_{o_2} = (0.99 - 0.7480)(1 - 0.7480^2) \approx 0.1066.$$

隐藏层误差信号：

$$\delta_{h_1} = (1 - h_1^2)(w_5\delta_{o_1} + w_6\delta_{o_2}) = (1 - 0.3649^2)(0.4 \times (-0.3355) + 0.45 \times 0.1066) \approx -0.0748,$$

$$\delta_{h_2} = (1 - h_2^2)(w_7\delta_{o_1} + w_8\delta_{o_2}) = (1 - 0.3714^2)(0.5 \times (-0.3355) + 0.55 \times 0.1066) \approx -0.0941.$$

步骤三：参数更新。

权值更新公式为 $w \leftarrow w + \eta \delta \cdot \text{input}$ ，其中 $\eta = 0.5$ 。

w_4 是 x_2 到 h_2 的权重，输入为 x_2 ：

$$w'_4 = w_4 + \eta \delta_{h_2} x_2 = 0.3 + 0.5 \times (-0.0941) \times 0.1 \approx 0.2953.$$

w_8 是 h_2 到 o_2 的权重，输入为 h_2 ：

$$w'_8 = w_8 + \eta \delta_{o_2} h_2 = 0.55 + 0.5 \times 0.1066 \times 0.3714 \approx 0.5698.$$

w_{01} 是偏置到 h_1 的权重，偏置输入恒为 1：

$$w'_{01} = w_{01} + \eta \delta_{h_1} \times 1 = 0.35 + 0.5 \times (-0.0748) \approx 0.3126.$$

六、BGD 的 BP 神经网络训练步骤

练习 30: BGD 的 BP 神经网络训练步骤。 简述采用批量梯度下降 (BGD) 的 BP 神经网络的训练步骤。

批量梯度下降 (Batch Gradient Descent) 的特点是：每次参数更新都使用整个训练集计算梯度。采用 BGD 的 BP 神经网络训练步骤如下。

第 1 步： 初始化网络结构，包括输入层、隐藏层、输出层的神经元数量。

第 2 步： 随机初始化所有权重和偏置，通常取较小的随机数以避免对称性问题。

第 3 步： 对训练集中的全部样本进行前向传播，计算每个样本的网络输出。

第 4 步： 根据输出值与真实标签计算损失函数值。

第 5 步： 从输出层开始反向传播，逐层计算损失函数对各权重和偏置的梯度。

第 6 步： 对全体训练样本的梯度求和或求平均，得到批量梯度。

第 7 步： 使用批量梯度下降更新参数：

$$w \leftarrow w - \eta \frac{\partial E}{\partial w}, \quad b \leftarrow b - \eta \frac{\partial E}{\partial b},$$

其中 η 为学习率。

第 8 步： 重复上述过程，直到达到最大训练轮数，或损失函数收敛，或满足早停条件。

上述步骤可简记为：

初始化参数 → 前向传播 → 计算损失 → 反向传播计算梯度 → 用全体样本平均梯度更新参数 → 重复迭代。

七、Softmax 与交叉熵

练习 31: Softmax 与交叉熵. 对于一个 10 分类神经网络，输出层采用 Softmax 层。样本 x 对应的标记 y 为：

$$[0, 0, 0, 0, 0, 1, 0, 0, 0, 0]^T$$

网络前向传播一次得到的输出为：

$$[0.2, 0.1, 0, 0, 0, 0.4, 0, 0.15, 0.15, 0]^T$$

试计算：

(1) 交叉熵损失为多少？

(2) 若前一隐层某神经元 h 的输出信号为 0.128， h 与输出层 10 个神经元的连接权重向量为

$$W = [0.1, -0.1, 0.2, -0.2, 0.3, -0.3, 0.4, -0.4, 0.5, -0.5]^T$$

取学习率 $\eta = 0.1$ ，请更新该权重向量。

已知数据整理。

真实标签 (one-hot 向量)：

$$y = [0, 0, 0, 0, 0, 1, 0, 0, 0, 0]^T.$$

预测输出 (Softmax 后的概率分布)：

$$\hat{y} = [0.2, 0.1, 0, 0, 0, 0.4, 0, 0.15, 0.15, 0]^T.$$

注意 $\hat{y}$ 各分量之和为 $0.2 + 0.1 + 0.4 + 0.15 + 0.15 = 1$ ，符合概率分布要求。

(1) **计算交叉熵损失。**

多分类交叉熵损失的定义为

$$L = - \sum_{j=1}^{10} y_j \ln \hat{y}_j.$$

由于 y 是 one-hot 向量，只有真实类别对应的项非零。本题真实类别为第 6 类 ($y_6 = 1$ ，其余 $y_j = 0$)，因此求和中只有 $j = 6$ 这一项有贡献：

$$L = -y_6 \ln \hat{y}_6 = -1 \times \ln 0.4 \approx 0.9163.$$

(2) **更新权重向量。**

首先推导梯度公式。神经元 h 的输出信号为 $h = 0.128$ ，它通过权重 W_j 连接到输出层第 j 个神经元。输出层第 j 个神经元的加权输入为

$$z_j = \cdots + W_j \cdot h + \cdots,$$

其中省略号表示其他前一层神经元的贡献。

Softmax 与交叉熵组合时，损失对 z_j 的梯度为

$$\frac{\partial L}{\partial z_j} = \hat{y}_j - y_j.$$

(这是 Softmax + 交叉熵的标准结论, 可由链式法则推导得到。)

由链式法则, 损失对权重 W_j 的梯度为

$$\frac{\partial L}{\partial W_j} = \frac{\partial L}{\partial z_j} \cdot \frac{\partial z_j}{\partial W_j} = (\hat{y}_j - y_j) \cdot h.$$

梯度下降更新公式为

$$W'_j = W_j - \eta \frac{\partial L}{\partial W_j} = W_j - \eta \cdot h \cdot (\hat{y}_j - y_j).$$

代入 $\eta = 0.1$ 、 $h = 0.128$, 得更新量

$$\Delta W_j = \eta \cdot h \cdot (\hat{y}_j - y_j) = 0.1 \times 0.128 \times (\hat{y}_j - y_j) = 0.0128(\hat{y}_j - y_j).$$

逐分量计算如下表:

j	W_j	$\hat{y}_j$	y_j	$\hat{y}_j - y_j$	ΔW_j	W'_j
1	0.1	0.2	0	0.2	0.00256	0.09744
2	-0.1	0.1	0	0.1	0.00128	-0.10128
3	0.2	0	0	0	0	0.2
4	-0.2	0	0	0	0	-0.2
5	0.3	0	0	0	0	0.3
6	-0.3	0.4	1	-0.6	-0.00768	-0.29232
7	0.4	0	0	0	0	0.4
8	-0.4	0.15	0	0.15	0.00192	-0.40192
9	0.5	0.15	0	0.15	0.00192	0.49808
10	-0.5	0	0	0	0	-0.5

因此更新后的权重向量为

$$W' = \begin{pmatrix} 0.09744 \\ -0.10128 \\ 0.2 \\ -0.2 \\ 0.3 \\ -0.29232 \\ 0.4 \\ -0.40192 \\ 0.49808 \\ -0.5 \end{pmatrix}.$$

直观理解: 只有 $\hat{y}_j \neq y_j$ 的分量 (即 $j = 1, 2, 6, 8, 9$) 才会有权重更新。其中 $j = 6$ (真实类别) 的权重变化最大 (-0.00768), 因为预测概率 0.4 与真实标签 1 差距最大。

10. 第 10 章: 深度学习

九、卷积层参数量

练习 32: 卷积层参数量. 一个卷积神经网络的输入为 $32 \times 32 \times 3$ 的图像, 第一个隐藏层卷积核大小为 5×5 , 共 10 个卷积核。请问这一层总共含有多少参数 (含偏置参数)?

输入通道数为 3, 每个卷积核大小为 5×5 , 因此一个卷积核含

$$5 \times 5 \times 3 = 75$$

个权重。每个卷积核再配一个偏置参数，共 76 个参数。该层有 10 个卷积核，所以总参数量为

$$10 \times (75 + 1) = 760.$$