



目录

1 第 1 章：概论	1
一、名词解释	1
二、回归与欠拟合/过拟合	1
五、KNN 分类模型	2
2 第 2 章：模型选择与评估	2
一、名词解释	2
四、ROC 与 AUC	2
3 第 3 章：贝叶斯分类器	4
一、名词解释	4
五、贝叶斯决策	4
六、朴素贝叶斯分类器	5
4 第 4 章：线性模型	5
一、名词解释	5
三、一对多判别边界	6
四、LDA 投影	7
七、交叉熵损失	8
5 第 5 章：决策树	8
一、名词解释	8
四、最小二乘回归树	9
五、ID3 与 CART 决策树	11
6 第 6 章：集成学习	12
一、名词解释	12
二、AdaBoost 权重迭代关系	12
三、AdaBoost 强分类过程	12
7 第 7 章：维度归约	13
一、名词解释	13
四、正交投影矩阵	13
五、PCA 与 LDA 投影方向	14
六、PCA 主分量与方差贡献率	16
8 第 8 章：聚类	16
一、名词解释	16
二、k-means 与 kNN	16
四、k-means 聚类	17
五、聚类算法选择	17

9 第 9 章：神经网络	18
一、TensorFlow 神经网络网页与二分类网络模型	18
二、名词解释	18
五、BP 神经网络一次迭代	19
六、BGD 的 BP 神经网络训练步骤	19
七、Softmax 与交叉熵	20
10 第 10 章：深度学习	20
九、卷积层参数量	20

1. 第 1 章：概论


一、名词解释

练习 1：名词解释. 解释以下概念：特征空间、假设空间、标记空间。

- 特征空间** 样本用特征向量表示后可能取值的空间。若样本有 d 个数值特征，常写为 $\mathcal{X} \subseteq \mathbb{R}^d$ ，每个样本 $x = (x_1, \dots, x_d)^T$ 是特征空间中的一个点。
- 假设空间** 学习算法可能输出的模型或函数集合，记为 $\mathcal{H}$ 。学习过程本质上是在 $\mathcal{H}$ 中根据训练数据选择一个假设 $h: \mathcal{X} \rightarrow \mathcal{Y}$ 。
- 标记空间** 监督学习中样本标记可能取值的集合，记为 $\mathcal{Y}$ 。分类任务的标记空间通常是有限类别集合，回归任务的标记空间通常是实数集或实数向量空间。

二、回归与欠拟合/过拟合

练习 2：回归与欠拟合/过拟合. 如下图是通过 GDP 对幸福度进行回归，蓝色点为已知样本，蓝色线表示回归曲线。判断模型属于欠拟合还是过拟合，并解释欠拟合、过拟合的定义、对未知样本预测的影响及解决方法。



- 图中的蓝色回归曲线剧烈振荡，在训练样本附近刻意贴合，而在样本外区域出现不合理的垂直跳变，因此属于**过拟合**。
- 欠拟合指模型复杂度不足，连训练数据中的主要规律也没有学到，表现为训练误差和测试误差都较大。过拟合指模型把训练集中的噪声或偶然性也当成规律学习，表现为训练误差很小但泛化误差较大。欠拟合时，对未知样本的预测通常偏差较大；过拟合时，对未知样本的预测方差较大，对训练集以外的数据不稳定。
- 解决过拟合的常见方法包括降低模型复杂度、增加正则化、剪枝、早停、数据增强、扩大训练集、使用交叉验证选择超参数等。解决欠拟合的常见方法包括提高模型复杂度、加入更有效的特征、减弱正则化、延长训练或选择表达能力更强的模型。

五、KNN 分类模型

练习 3: KNN 分类模型. KNN 分类模型中, K 是什么意思? 简述该模型的工作流程。

KNN 中的 K 表示参与投票的最近邻样本个数。给定测试样本 x , KNN 的基本流程是: 计算 x 与训练集中各样本的距离; 选出距离最近的 K 个样本; 分类任务中按多数表决决定类别, 回归任务中通常取邻居标记的平均值或加权平均值。 K 较小时模型更敏感、方差较大; K 较大时模型更平滑、偏差较大。

2. 第 2 章: 模型选择与评估

一、名词解释

练习 4: 名词解释. 解释以下概念: 经验误差、泛化误差、训练集、测试集、验证集、查准率、查全率、分层采样、交叉验证、自助采样。

经验误差 学习器在训练集上的平均损失, 也称训练误差。

泛化误差 学习器在未知样本总体上的期望损失, 反映模型对新数据的预测能力。

训练集 用于拟合模型参数的数据集。

测试集 训练完成后用于估计泛化性能的数据集, 原则上不参与模型选择。

验证集 训练过程中用于选择超参数、模型结构或早停轮数的数据集。

查准率 预测为正的样本中真正为正的比率, $P = \frac{TP}{TP + FP}$ 。

查全率 全部真实正例中被正确检出的比例, $R = \frac{TP}{TP + FN}$ 。

分层采样 按类别比例分别抽样, 使训练集、验证集、测试集尽量保持原始类别分布。

交叉验证 将数据划分为若干份, 轮流用其中一份验证、其余训练, 并汇总多次验证结果估计性能。

自助采样 从含 m 个样本的数据集中有放回地抽取 m 次形成训练集, 未被抽中的样本可作包外测试。

四、ROC 与 AUC

练习 5: ROC 与 AUC. 已知 8 个测试样本中有 4 个正例、4 个反例, 预测结果为

$(s_1, 0.80, +), (s_2, 0.70, +), (s_3, 0.56, -), (s_4, 0.50, +),$

$(s_5, 0.50, -), (s_6, 0.30, +), (s_7, 0.20, -), (s_8, 0.15, -).$

画出 ROC 曲线, 并给出 AUC 的值。

正例数和反例数均为 4。按预测分数从高到低移动阈值, 并将分数相同的 s_4 与 s_5 在同一阈值处同时加入, ROC 点为

$(0, 0), (0, \frac{1}{4}), (0, \frac{1}{2}), (\frac{1}{4}, \frac{1}{2}), (\frac{1}{2}, \frac{3}{4}), (\frac{1}{2}, 1), (\frac{3}{4}, 1), (1, 1).$

其中横轴为假正例率 $FPR = FP/4$, 纵轴为真正例率 $TPR = TP/4$ 。用梯形面积计算,

$$AUC = \frac{25}{32} = 0.78125.$$

若忽略同分样本的并列处理并严格按题目给出的排列逐点连接, 则会得到 $AUC = 13/16 = 0.8125$; 标准做法通常采用并列平均, 因此这里取 0.78125。




图 1: 8 个测试样本的 ROC 曲线

作图代码如下。

```

1 from pathlib import Path
2
3 import matplotlib.pyplot as plt
4 import numpy as np
5
6
7 samples = [
8     ("s1", 0.80, 1),
9     ("s2", 0.70, 1),
10    ("s3", 0.56, 0),
11    ("s4", 0.50, 1),
12    ("s5", 0.50, 0),
13    ("s6", 0.30, 1),
14    ("s7", 0.20, 0),
15    ("s8", 0.15, 0),
16 ]
17
18 scores = sorted({score for _, score, _ in samples}, reverse=True)
19 p = sum(label for _, _, label in samples)
20 n = len(samples) - p
21
22 roc_points = [(0.0, 0.0)]
23 for threshold in scores:
24     tp = sum(label == 1 and score >= threshold for _, score, label in samples)
25     fp = sum(label == 0 and score >= threshold for _, score, label in samples)
26     roc_points.append((fp / n, tp / p))
27
28 xs = np.array([point[0] for point in roc_points])
29 ys = np.array([point[1] for point in roc_points])
30 auc = np.trapezoid(ys, xs)
31
32 plt.rcParams.update(
33     {
34         "pdf.fonttype": 42,
35         "ps.fonttype": 42,
36         "font.size": 10,
37     }
38 )
39
40 fig, ax = plt.subplots(figsize=(4.2, 4.0))
41 ax.plot(xs, ys, marker="o", color="#1f77b4", linewidth=2)
42 ax.plot([0, 1], [0, 1], "--", color="0.65", linewidth=1)
43 for (x, y), label in zip(roc_points[1:], [f"score={s:g}" for s in scores]):
44     ax.annotate(label, (x, y), xytext=(5, -12), textcoords="offset points", fontsize=8)
45 
```

```

46 ax.set_xlim(-0.03, 1.03)
47 ax.set_ylim(-0.03, 1.03)
48 ax.set_xticks(np.linspace(0, 1, 5))
49 ax.set_yticks(np.linspace(0, 1, 5))
50 ax.set_xlabel("False positive rate")
51 ax.set_ylabel("True positive rate")
52 ax.set_title(f"ROC curve, AUC = {auc:.5f}")
53 ax.grid(True, alpha=0.25)
54 fig.tight_layout()
55 fig.savefig(Path(__file__).with_suffix(".pdf"))

```

3. 第 3 章：贝叶斯分类器

一、名词解释

练习 6: 名词解释. 解释以下概念：后验概率、朴素贝叶斯分类器。

后验概率 在观测到样本 x 后，样本属于类别 ω_i 的条件概率 $P(\omega_i | x)$ 。由贝叶斯公式，

$$P(\omega_i | x) = \frac{P(x | \omega_i)P(\omega_i)}{\sum_j P(x | \omega_j)P(\omega_j)}.$$

朴素贝叶斯分类器

在给定类别条件下假设各特征条件独立的贝叶斯分类器。其判别规则为

$$\hat{y} = \arg \max_c P(c) \prod_{j=1}^d P(x_j | c).$$

五、贝叶斯决策

练习 7: 贝叶斯决策. 已知 $P(\omega_1) = 0.7$, $P(\omega_2) = 0.3$, $P(x | \omega_1) = 0.15$, $P(x | \omega_2) = 0.45$, 损失矩阵为

$$\begin{pmatrix} 0 & 5 \\ 1 & 0 \end{pmatrix}.$$

分别用最小错误率和最小风险的贝叶斯决策对样本 x 分类，并写出判别函数和决策方程。

未归一化后验为

$$P(x | \omega_1)P(\omega_1) = 0.15 \times 0.7 = 0.105, \quad P(x | \omega_2)P(\omega_2) = 0.45 \times 0.3 = 0.135.$$

归一化因子为 0.24，因此

$$P(\omega_1 | x) = 0.4375, \quad P(\omega_2 | x) = 0.5625.$$

(1) 最小错误率贝叶斯决策的判别函数可取

$$g_i(x) = P(x | \omega_i)P(\omega_i) \quad \text{或} \quad g_i(x) = P(\omega_i | x).$$

决策方程为

$$\hat{\omega} = \arg \max_i g_i(x).$$

因为 $g_2(x) = 0.135 > g_1(x) = 0.105$ ，所以判为 ω_2 ，即患者。

(2) 设 λ_{ij} 表示判为 ω_i 而真实为 ω_j 的损失。两个决策风险为

$$R(\alpha_1 | x) = 0 \cdot P(\omega_1 | x) + 5P(\omega_2 | x) = 2.8125,$$

$$R(\alpha_2 | x) = 1 \cdot P(\omega_1 | x) + 0 \cdot P(\omega_2 | x) = 0.4375.$$

最小风险决策方程为

$$\hat{\alpha} = \arg \min_i R(\alpha_i | x).$$

因为 $R(\alpha_2 | x) < R(\alpha_1 | x)$, 所以仍判为 ω_2 。等价地, 当

$$5P(\omega_2 | x) < P(\omega_1 | x)$$

时判为正常, 否则判为患者; 本题不满足该不等式。

六、朴素贝叶斯分类器

练习 8: 朴素贝叶斯分类器. 根据题中给定的 15 个二维离散样本构造朴素贝叶斯分类器, 判断 $x = (2020, P)^T$ 的类别。两个特征取值分别为 $\{2019, 2020, 2021\}$ 和 $\{P, N, T\}$, 类别为 $\{-1, 1\}$ 。

类别先验概率为

$$P(y = 1) = \frac{9}{15} = \frac{3}{5}, \quad P(y = -1) = \frac{6}{15} = \frac{2}{5}.$$

不使用拉普拉斯平滑时,

$$P(x_1 = 2020 | y = 1) = \frac{3}{9} = \frac{1}{3}, \quad P(x_2 = P | y = 1) = \frac{1}{9},$$

$$P(x_1 = 2020 | y = -1) = \frac{2}{6} = \frac{1}{3}, \quad P(x_2 = P | y = -1) = \frac{3}{6} = \frac{1}{2}.$$

于是

$$P(y = 1) \prod_j P(x_j | y = 1) = \frac{3}{5} \cdot \frac{1}{3} \cdot \frac{1}{9} = \frac{1}{45},$$

$$P(y = -1) \prod_j P(x_j | y = -1) = \frac{2}{5} \cdot \frac{1}{3} \cdot \frac{1}{2} = \frac{1}{15}.$$

由于 $\frac{1}{15} > \frac{1}{45}$, 故

$$x = (2020, P)^T \text{ 判为 } y = -1.$$

若采用拉普拉斯平滑, 结论仍为 $y = -1$ 。

4. 第 4 章: 线性模型

一、名词解释

练习 9: 名词解释. 解释以下概念: 基函数、联系函数、支持向量 (SV)、梯度下降法、交叉熵、代价函数。

基函数 将原始输入映射为新特征的函数, 如 $\phi_j(x)$ 。线性模型可写为 $f(x) = \sum_j w_j \phi_j(x)$ 。

联系函数 广义线性模型中连接条件均值与线性预测项的函数, 如逻辑回归中的 logit 函数。

支持向量 SVM 中位于间隔边界上或违反间隔约束、对分类超平面起决定作用的训练样本。

梯度下降法 沿目标函数负梯度方向迭代更新参数的方法: $\theta \leftarrow \theta - \eta \nabla_{\theta} J(\theta)$ 。

交叉熵 衡量真实分布 p 与预测分布 q 差异的损失, $H(p, q) = -\sum_i p_i \log q_i$ 。

代价函数 学习算法需要最小化的总体目标函数, 通常由经验损失和正则化项组成。

三、一对多判别边界

练习 10: 一对多判别边界. 已知三个判别函数

$$g_1(x) = -x_1 - x_2 + 5, \quad g_2(x) = -x_1 + 3, \quad g_3(x) = -x_1 + x_2.$$

画出一对多情况下的判别边界及三个类别的判别区域, 并判断 (1, 3) 和 (4, 5) 的类别。

三个边界分别为

$$g_1(x) = 0 : x_1 + x_2 = 5, \quad g_2(x) = 0 : x_1 = 3, \quad g_3(x) = 0 : x_2 = x_1.$$

一对多分类中, 若恰有一个判别函数为正, 则判为对应类别; 若多个为正或全为负, 则类别不能唯一确定。因此三个确定分类区域为

$$\omega_1 : g_1 > 0, g_2 < 0, g_3 < 0,$$

$$\omega_2 : g_2 > 0, g_1 < 0, g_3 < 0,$$

$$\omega_3 : g_3 > 0, g_1 < 0, g_2 < 0.$$

对样本 (1, 3),

$$(g_1, g_2, g_3) = (1, 2, 2),$$

三个分类器均给出正类, 发生冲突, 类别不能确定。对样本 (4, 5),

$$(g_1, g_2, g_3) = (-4, -1, 1),$$

仅 $g_3 > 0$, 故判为 ω_3 。




图 2: 一对多判别边界与确定分类区域

作图代码如下。

```
1 from pathlib import Path
2
3 import matplotlib.pyplot as plt
4 import numpy as np
5 from matplotlib.colors import ListedColormap
```

```

6
7
8 def scores(x1, x2):
9     return np.stack(
10         [
11             -x1 - x2 + 5,
12             -x1 + 3,
13             -x1 + x2,
14         ],
15         axis=0,
16     )
17
18
19 plt.rcParams.update(
20     {
21         "pdf.fonttype": 42,
22         "ps.fonttype": 42,
23         "font.size": 10,
24     }
25 )
26
27 x = np.linspace(-1.0, 7.0, 500)
28 y = np.linspace(-2.0, 7.0, 500)
29 xx, yy = np.meshgrid(x, y)
30 g = scores(xx, yy)
31 positive = g > 0
32 region = np.zeros_like(xx, dtype=int)
33 for idx in range(3):
34     region[(positive[idx]) & (positive.sum(axis=0) == 1)] = idx + 1
35 region[positive.sum(axis=0) != 1] = 0
36
37 fig, ax = plt.subplots(figsize=(5.2, 4.6))
38 cmap = ListedColormap(["#f0f0f0", "#f8d7da", "#d8f3dc", "#d6eaf8"])
39 ax.contourf(xx, yy, region, levels=[-0.5, 0.5, 1.5, 2.5, 3.5], cmap=cmap, alpha=0.78)
40
41 line_x = np.linspace(-1.0, 7.0, 300)
42 ax.plot(line_x, 5 - line_x, color="#b91c1c", linewidth=2, label=r"$g_1=0$")
43 ax.axvline(3, color="#15803d", linewidth=2, label=r"$g_2=0$")
44 ax.plot(line_x, line_x, color="#1d4ed8", linewidth=2, label=r"$g_3=0$")
45
46 ax.scatter([1, 4], [3, 5], color="black", zorder=5)
47 ax.annotate("(1, 3)", (1, 3), xytext=(6, 6), textcoords="offset points")
48 ax.annotate("(4, 5)", (4, 5), xytext=(6, 6), textcoords="offset points")
49 ax.text(4.4, -1.1, r"$\omega_1$", color="#7f1d1d", fontsize=13)
50 ax.text(2.63, 2.86, r"$\omega_2$", color="#14532d", fontsize=13)
51 ax.text(4.8, 5.8, r"$\omega_3$", color="#1e3a8a", fontsize=13)
52 ax.text(-0.85, 6.25, "ambiguous / reject", color="0.35", fontsize=9)
53
54 ax.set_xlim(-1.0, 7.0)
55 ax.set_ylim(-2.0, 7.0)
56 ax.set_xlabel(r"$x_1$")
57 ax.set_ylabel(r"$x_2$")
58 ax.set_aspect("equal", adjustable="box")
59 ax.grid(True, alpha=0.2)
60 ax.legend(loc="lower left", frameon=True)
61 fig.tight_layout()
62 fig.savefig(Path(__file__).with_suffix(".pdf"))

```

四、LDA 投影

练习 11: LDA 投影. (1) 已知 LDA 最佳投影直线为 $5x_1 - 2x_2 + 1 = 0$, 求 $(2, 0)^T$ 、 $(-1, -7)^T$ 在该直线上的投影; (2) 推导样本在直线 w 上投影点的协方差为 $w^T \Sigma_0 w$.

(1) 直线为 $5x_1 - 2x_2 + 1 = 0$, 法向量 $n = (5, -2)^T$. 点 x 到该直线的正交投影为

$$x' = x - \frac{n^T x + 1}{\|n\|^2} n, \quad \|n\|^2 = 29.$$

对 $x = (2, 0)^T$,

$$x' = (2, 0)^T - \frac{11}{29}(5, -2)^T = \left(\frac{3}{29}, \frac{22}{29}\right)^T.$$

对 $x = (-1, -7)^T$,

$$x' = (-1, -7)^T - \frac{10}{29}(5, -2)^T = \left(-\frac{79}{29}, -\frac{183}{29}\right)^T.$$

(2) 设样本 x 的均值为 μ , 协方差为 $\Sigma_0 = E[(x - \mu)(x - \mu)^T]$ 。在方向 w 上的一维投影为 $z = w^T x$, 则

$$\text{Var}(z) = E[(w^T x - w^T \mu)^2] = E[w^T (x - \mu)(x - \mu)^T w] = w^T \Sigma_0 w.$$

七、交叉熵损失

练习 12: 交叉熵损失. 已知 10 个二分类样本标签为 $(0, 1, 1, 1, 0, 0, 0, 0, 1, 0)$, 分类器给出的正类概率为

$$(0.1, 0.88, 0.92, 0.65, 0.2, 0.3, 0.4, 0.1, 0.85, 0.1).$$

计算这 10 个样本的交叉熵损失。

二分类交叉熵取自然对数:

$$L = - \sum_{i=1}^{10} [y_i \log p_i + (1 - y_i) \log(1 - p_i)].$$

逐项相加得

$$L = 2.2112.$$

若按样本平均, 则

$$\bar{L} = \frac{L}{10} = 0.2211.$$

5. 第 5 章: 决策树

一、名词解释

练习 13: 名词解释. 解释以下概念: 熵和条件熵、信息增益、基尼指数。

熵和条件熵 熵衡量随机变量不确定性: $H(Y) = -\sum_k p_k \log_2 p_k$ 。条件熵衡量给定 X 后 Y 的平均不确定性: $H(Y | X) = \sum_x P(X = x) H(Y | X = x)$ 。

信息增益 用属性 A 划分数据集 D 后不确定性的减少量:

$$\text{Gain}(D, A) = H(D) - H(D | A).$$

ID3 每次选择信息增益最大的属性。

基尼指数 CART 分类树常用的不纯度指标:

$$\text{Gini}(D) = 1 - \sum_k p_k^2.$$

基尼指数越小, 节点越纯。

四、最小二乘回归树

练习 14: 最小二乘回归树. 根据样本

$$x = (1, 2, \dots, 10), \quad y = (4.5, 4.75, 4.91, 5.34, 5.8, 7.05, 7.9, 8.23, 8.7, 9.5),$$

生成一个深度 $\text{depth}=3$ 的最小二乘回归树并作图。

采用 CART 最小二乘准则，对每个候选切分点 s 计算

$$\sum_{x_i \leq s} (y_i - \bar{y}_L)^2 + \sum_{x_i > s} (y_i - \bar{y}_R)^2.$$

将根节点深度记为 0，取 $\text{max_depth}=3$ 。根节点候选切分中， $s = 5.5$ 的误差最小，误差为 4.3827，因此先切分为 $x \leq 5.5$ 与 $x > 5.5$ 。继续递归切分得到

$$x \leq 5.5: \quad x \leq 3.5, \quad (x \leq 1.5), \quad (x \leq 4.5),$$

$$x > 5.5: \quad x \leq 8.5, \quad (x \leq 6.5), \quad (x \leq 9.5).$$

最终叶节点预测值为各叶节点内样本 y 的均值：

区间	预测值
$x \leq 1.5$	4.50
$1.5 < x \leq 3.5$	4.83
$3.5 < x \leq 4.5$	5.34
$4.5 < x \leq 5.5$	5.80
$5.5 < x \leq 6.5$	7.05
$6.5 < x \leq 8.5$	8.065
$8.5 < x \leq 9.5$	8.70
$x > 9.5$	9.50




图 3: 深度为 3 的最小二乘回归树

作图代码如下。

```

1 from pathlib import Path
2
3 import matplotlib.pyplot as plt
4 import numpy as np
5
6 
```

```

7 x = np.arange(1, 11, dtype=float)
8 y = np.array([4.50, 4.75, 4.91, 5.34, 5.80, 7.05, 7.90, 8.23, 8.70, 9.50])
9
10 leaf_intervals = [
11     (1.0, 1.5, 4.50),
12     (1.5, 3.5, 4.83),
13     (3.5, 4.5, 5.34),
14     (4.5, 5.5, 5.80),
15     (5.5, 6.5, 7.05),
16     (6.5, 8.5, 8.065),
17     (8.5, 9.5, 8.70),
18     (9.5, 10.0, 9.50),
19 ]
20
21 nodes = {
22     "root": (0.50, 0.94, r"$x \leq 5.5$"),
23     "l": (0.25, 0.72, r"$x \leq 3.5$"),
24     "r": (0.75, 0.72, r"$x \leq 8.5$"),
25     "ll": (0.125, 0.50, r"$x \leq 1.5$"),
26     "lr": (0.375, 0.50, r"$x \leq 4.5$"),
27     "rl": (0.625, 0.50, r"$x \leq 6.5$"),
28     "rr": (0.875, 0.50, r"$x \leq 9.5$"),
29     "a": (0.055, 0.25, r"$4.50$"),
30     "b": (0.195, 0.25, r"$4.83$"),
31     "c": (0.305, 0.25, r"$5.34$"),
32     "d": (0.445, 0.25, r"$5.80$"),
33     "e": (0.555, 0.25, r"$7.05$"),
34     "f": (0.695, 0.25, r"$8.065$"),
35     "g": (0.805, 0.25, r"$8.70$"),
36     "h": (0.945, 0.25, r"$9.50$"),
37 }
38 edges = [
39     ("root", "l", "yes"),
40     ("root", "r", "no"),
41     ("l", "ll", "yes"),
42     ("l", "lr", "no"),
43     ("r", "rl", "yes"),
44     ("r", "rr", "no"),
45     ("ll", "a", "yes"),
46     ("ll", "b", "no"),
47     ("lr", "c", "yes"),
48     ("lr", "d", "no"),
49     ("rl", "e", "yes"),
50     ("rl", "f", "no"),
51     ("rr", "g", "yes"),
52     ("rr", "h", "no"),
53 ]
54
55 plt.rcParams.update(
56     {
57         "pdf.fonttype": 42,
58         "ps.fonttype": 42,
59         "font.size": 10,
60     }
61 )
62
63 fig, (ax_fit, ax_tree) = plt.subplots(
64     1, 2, figsize=(10.5, 4.3), gridspec_kw={"width_ratios": [1.05, 1.35]}
65 )
66
67 ax_fit.scatter(x, y, color="#1f77b4", zorder=3, label="samples")
68 for left, right, value in leaf_intervals:
69     ax_fit.hlines(value, left, right, colors="#d62728", linewidth=2.2)
70 for threshold in [1.5, 3.5, 4.5, 5.5, 6.5, 8.5, 9.5]:
71     ax_fit.axvline(threshold, color="0.75", linestyle="--", linewidth=0.8)
72 ax_fit.set_xlabel(r"$x$")
73 ax_fit.set_ylabel(r"$y$")
74 ax_fit.set_xlim(0.7, 10.3)
75 ax_fit.set_ylim(4.2, 9.8)
76 ax_fit.set_title("Piecewise constant prediction")
77 ax_fit.grid(True, alpha=0.2)
78
79 ax_tree.axis("off")
80 for parent, child, label in edges:

```

```

81 x0, y0, _ = nodes[parent]
82 x1, y1, _ = nodes[child]
83 ax_tree.plot([x0, x1], [y0 - 0.03, y1 + 0.03], color="0.35", linewidth=1)
84 ax_tree.text((x0 + x1) / 2, (y0 + y1) / 2, label, fontsize=8, color="0.35")
85
86 for name, (nx, ny, text) in nodes.items():
87     is_leaf = name in list("abcdefgh")
88     bbox = dict(
89         boxstyle="round,pad=0.25",
90         facecolor="#fff7ed" if is_leaf else "#e0f2fe",
91         edgecolor="#334155",
92         linewidth=1,
93     )
94     ax_tree.text(nx, ny, text, ha="center", va="center", bbox=bbox)
95 ax_tree.set_title("Least-squares regression tree, max_depth=3")
96
97 fig.tight_layout()
98 fig.savefig(Path(__file__).with_suffix(".pdf"))

```

五、ID3 与 CART 决策树

练习 15: ID3 与 CART 决策树. 对题中给出的贷款申请样本表, 分别用 ID3 和 CART 算法生成决策树, 并写出主要计算步骤。属性包括年龄、有工作、有自己的房子、信贷情况, 类别为是否批准。

数据集中正例“是”有 12 个, 反例“否”有 6 个, 因此

$$H(D) = -\frac{12}{18} \log_2 \frac{12}{18} - \frac{6}{18} \log_2 \frac{6}{18} = 0.9183.$$

各属性的信息增益为

属性	$Gain(D, A)$
年龄	0.0285
有工作	0.3789
有自己的房子	0.4591
信贷情况	0.3572

最大者为“有自己的房子”, 故 ID3 根节点选择该属性。当“有自己的房子 = 是”时, 9 个样本全部为“是”, 直接为叶节点。当“有自己的房子 = 否”时, 子集含 6 个“否”、3 个“是”, 熵仍为 0.9183。在该子集上

属性	$Gain$
年龄	0.2516
有工作	0.9183
信贷情况	0.4739

故继续按“有工作”划分; “有工作 = 否”的样本全为“否”, “有工作 = 是”的样本全为“是”。ID3 决策树为

若有自己的房子 = 是, 则类别 = 是;
 若有自己的房子 = 否且有工作 = 是, 则类别 = 是;
 若有自己的房子 = 否且有工作 = 否, 则类别 = 否。

CART 使用基尼指数。根节点

$$Gini(D) = 1 - \left(\frac{12}{18}\right)^2 - \left(\frac{6}{18}\right)^2 = 0.4444.$$

对多值离散属性取最优二分切分时，各属性最小加权基尼指数为

属性	最小加权Gini
年龄	0.4308
有工作	0.2667
有自己的房子	0.2222
信贷情况	0.2769

最小者仍为“有自己的房子”，切分为“否”与“是”。“有自己的房子 = 是”分支纯度为 0。在“有自己的房子 = 否”子集上，继续按“有工作”切分时加权基尼指数为 0，两个分支均纯。因此 CART 树与上面的 ID3 树结构一致。

6. 第 6 章：集成学习

一、名词解释

练习 16：名词解释。解释概念：基学习器。

基学习器 集成学习中被组合的单个学习器，也称个体学习器或弱学习器。多个基学习器通过投票、加权投票、平均或堆叠等方式形成集成模型。

二、AdaBoost 权重迭代关系

练习 17：AdaBoost 权重迭代关系。复习 AdaBoost 算法，推导样本 x_i 第 t 轮权重与第 $t+1$ 轮权重满足

$$w_{t+1,i} = \begin{cases} \frac{w_{t,i}}{2(1-e_t)}, & \text{分类正确,} \\ \frac{w_{t,i}}{2e_t}, & \text{分类错误.} \end{cases}$$

AdaBoost 第 t 轮样本权重更新为

$$w_{t+1,i} = \frac{w_{t,i} \exp(-\alpha_t y_i h_t(x_i))}{Z_t}, \quad \alpha_t = \frac{1}{2} \ln \frac{1-e_t}{e_t}.$$

其中 $y_i h_t(x_i) = 1$ 表示分类正确， $y_i h_t(x_i) = -1$ 表示分类错误。归一化因子为

$$Z_t = (1-e_t)e^{-\alpha_t} + e_t e^{\alpha_t} = 2\sqrt{e_t(1-e_t)}.$$

若分类正确，

$$w_{t+1,i} = \frac{w_{t,i} e^{-\alpha_t}}{Z_t} = \frac{w_{t,i}}{2(1-e_t)}.$$

若分类错误，

$$w_{t+1,i} = \frac{w_{t,i} e^{\alpha_t}}{Z_t} = \frac{w_{t,i}}{2e_t}.$$


这正是题中给出的迭代关系。

三、AdaBoost 强分类过程

练习 18：AdaBoost 强分类过程。给定 10 个训练样本和弱学习器

$$h_1 = \begin{cases} 1, & X_1 < 2.5 \\ -1, & X_1 > 2.5 \end{cases}, \quad h_2 = \begin{cases} 1, & X_1 < 8.5 \\ -1, & X_1 > 8.5 \end{cases}, \quad h_3 = \begin{cases} 1, & X_2 > 6.5 \\ -1, & X_2 < 6.5 \end{cases}.$$

用 AdaBoost 算法实现强分类过程。



初始权重 $D_1(i) = 0.1$ 。三个弱分类器第一轮错误率均为 0.3，按题目给出的顺序选 h_1 。计算过程为

t	h_t	错分样本	e_t	α_t
1	h_1	5, 7, 8	3/10	$\frac{1}{2} \ln \frac{7}{3} = 0.4236$
2	h_2	3, 4, 6	3/14	$\frac{1}{2} \ln \frac{11}{3} = 0.6496$
3	h_3	1, 2, 9	3/22	$\frac{1}{2} \ln \frac{19}{3} = 0.9229$

因此强分类器为

$$H(x) = \text{sign}(0.4236h_1(x) + 0.6496h_2(x) + 0.9229h_3(x)).$$

对 10 个训练样本，强分类器的加权输出符号为

$$(+, +, -, -, +, -, +, +, -, -),$$

与给定类别完全一致。

7. 第 7 章：维度归约

一、名词解释

练习 19: 名词解释. 解释概念：测地线 (geodesic) 距离。

测地线距离 在流形或曲面上沿该流形可行路径连接两点的最短路径长度。与欧氏距离不同，测地线距离考虑数据所在流形的弯曲结构。


四、正交投影矩阵

练习 20: 正交投影矩阵. 降维分析中涉及投影的变换矩阵通常要求正交。说明正交投影矩阵相对于非正交投影矩阵的优点，并解释为什么 PCA 中变换矩阵一定可以取为正交矩阵。

- (1) 正交投影矩阵的列向量相互正交且通常归一化，优点是投影后的坐标不冗余，不会人为引入斜交坐标造成的尺度耦合；长度、角度和方差解释更清楚，数值计算也更稳定。非正交投影可能把不同方向的信息混在一起，使投影坐标相关，解释性和重构分析都较差。
- (2) PCA 的投影方向来自样本协方差矩阵的特征向量。协方差矩阵是实对称矩阵，不同特征值对应的特征向量正交；重特征值对应的特征子空间也可以选取一组正交规范基。因此 PCA 的变换矩阵可取为正交矩阵。

五、PCA 与 LDA 投影方向

练习 21: PCA 与 LDA 投影方向. 参照题图, 绘制一个二维数据集示例, 使 PCA 和 LDA 找到相同的好方向; 再绘制一个数据集, 使 PCA 和 LDA 都找不到好的投影方向。



当两类样本的均值差方向也是总方差最大的方向时, PCA 和 LDA 会找到相同的好方向。例如两团数据左右分离, 主要差异在 x 轴方向。相反, XOR 型数据中两类均值相同, 类别信息不是任何单一线性投影能表达的; PCA 只看总体方差, LDA 的类均值差又为零, 两者都找不到好的投影方向。




图 4: PCA 与 LDA 投影方向示例

作图代码如下。

```
1 from pathlib import Path
2
3 import matplotlib.pyplot as plt
4 import numpy as np
5
6
7 def unit(v):
8     norm = np.linalg.norm(v)
9     return v / norm if norm > 1e-12 else v
10
11
12 def pca_direction(x):
13     centered = x - x.mean(axis=0)
14     cov = centered.T @ centered / len(x)
15     values, vectors = np.linalg.eigh(cov)
16     return unit(vectors[:, np.argmax(values)])
17
18
19 def lda_direction(x, y):
20     classes = np.unique(y)
21     means = [x[y == c].mean(axis=0) for c in classes]
22     sw = np.zeros((2, 2))
23     for c, mean in zip(classes, means):
24         z = x[y == c] - mean
25         sw += z.T @ z
26     diff = means[1] - means[0]
```

```

27     if np.linalg.norm(diff) < 1e-12:
28         return np.zeros(2)
29     return unit(np.linalg.pinv(sw) @ diff)
30
31
32 rng = np.random.default_rng(7)
33 good_a = rng.normal(loc=(-2.0, 0.0), scale=(0.45, 0.55), size=(35, 2))
34 good_b = rng.normal(loc=(2.0, 0.0), scale=(0.45, 0.55), size=(35, 2))
35 good_x = np.vstack([good_a, good_b])
36 good_y = np.array([0] * len(good_a) + [1] * len(good_b))
37
38 offsets = np.array(
39     [
40         [-0.16, -0.10],
41         [-0.11, 0.12],
42         [0.08, -0.14],
43         [0.19, 0.08],
44     ]
45 )
46 bad_a = np.vstack([offsets + (-1, -1), offsets + (1, 1)])
47 bad_b = np.vstack([offsets + (-1, 1), offsets + (1, -1)])
48 bad_x = np.vstack([bad_a, bad_b])
49 bad_y = np.array([0] * len(bad_a) + [1] * len(bad_b))
50
51 plt.rcParams.update(
52     {
53         "pdf.fonttype": 42,
54         "ps.fonttype": 42,
55         "font.size": 10,
56     }
57 )
58
59 fig, axes = plt.subplots(1, 2, figsize=(9.2, 4.1))
60 for ax, x, y, title in [
61     (axes[0], good_x, good_y, "PCA and LDA find the same useful direction"),
62     (axes[1], bad_x, bad_y, "XOR: no good linear projection"),
63 ]:
64     ax.scatter(x[y == 0, 0], x[y == 0, 1], marker="o", facecolors="none", edgecolors="#2563eb", label="class 0")
65     ax.scatter(x[y == 1, 0], x[y == 1, 1], marker="+", color="#dc2626", s=65, label="class 1")
66     center = x.mean(axis=0)
67     p_dir = pca_direction(x)
68     l_dir = lda_direction(x, y)
69     for direction, color, name, offset in [
70         (p_dir, "#0f766e", "PCA", 0.10),
71         (l_dir, "#9333ea", "LDA", -0.10),
72     ]:
73         if np.linalg.norm(direction) < 1e-12:
74             ax.text(center[0] - 1.1, center[1] - 1.45, "LDA direction undefined", color=color)
75             continue
76         start = center - 1.5 * direction + offset * np.array([-direction[1], direction[0]])
77         end = center + 1.5 * direction + offset * np.array([-direction[1], direction[0]])
78         ax.annotate(
79             "",
80             xy=end,
81             xytext=start,
82             arrowprops=dict(arrowstyle="->", color=color, linewidth=2),
83         )
84         ax.text(*(end + 0.08), name, color=color, fontsize=10)
85     ax.axhline(0, color="0.85", linewidth=0.8)
86     ax.axvline(0, color="0.85", linewidth=0.8)
87     ax.set_aspect("equal", adjustable="box")
88     ax.set_title(title)
89     ax.grid(True, alpha=0.2)
90
91 axes[0].legend(loc="lower right", frameon=True)
92 fig.tight_layout()
93 fig.savefig(Path(__file__).with_suffix(".pdf"))

```


六、PCA 主分量与方差贡献率

练习 22: PCA 主分量与方差贡献率. 用 PCA 方法计算 6 个二维样本

$$\begin{pmatrix} 2 & 3 & 3 & 4 & 5 & 7 \\ 2 & 4 & 5 & 5 & 6 & 8 \end{pmatrix}$$

的一维 PCA 主分量, 并计算该主分量的方差贡献率。注意: 样本未中心化。

题目给出的样本未中心化, 先求均值

$$\mu = (4, 5)^T.$$

中心化后的样本为

$$X_c = \begin{pmatrix} -2 & -1 & -1 & 0 & 1 & 3 \\ -3 & -1 & 0 & 0 & 1 & 3 \end{pmatrix}.$$

协方差矩阵可取

$$\Sigma = \frac{1}{6} X_c X_c^T = \begin{pmatrix} 2.6667 & 2.8333 \\ 2.8333 & 3.3333 \end{pmatrix}.$$

其特征值为

$$\lambda_1 = 5.8529, \quad \lambda_2 = 0.1471.$$

最大特征值对应的单位特征向量可取

$$u_1 = (0.6645, 0.7473)^T.$$

因此一维 PCA 主分量方向为 u_1 , 对应的一维投影坐标为

$$X_c^T u_1 = (-3.5709, -1.4118, -0.6645, 0, 1.4118, 4.2354)^T.$$

方差贡献率为

$$\frac{\lambda_1}{\lambda_1 + \lambda_2} = 0.9755,$$

约为 97.55%。

8. 第 8 章: 聚类

一、名词解释

练习 23: 名词解释. 解释以下概念: Jaccard 系数、密度可达。

Jaccard 系数

用于衡量两个集合相似度:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}.$$

在二值特征中, 它只关注两个样本同时取 1 与至少一个取 1 的特征。

密度可达

在 DBSCAN 中, 若存在样本链 $p_1, \dots, p_n$, 其中 $p_1 = q$, $p_n = p$, 且每个 p_{i+1} 都从核心点 p_i 直接密度可达, 则称 p 从 q 密度可达。

二、k-means 与 kNN

练习 24: k-means 与 kNN. k-means 算法与 kNN 方法中的 k 分别指什么? 这两个方法的主要区别是什么?

k-means 中的 k 表示要划分出的簇数；kNN 中的 k 表示预测时参与投票或平均的最近邻样本个数。k-means 是无监督聚类算法，没有训练标签，目标是 minimize 簇内平方误差；kNN 是监督学习方法，需要带标签训练样本，预测时根据邻居标签决定输出。k-means 会学习簇中心，kNN 通常是惰性学习，预测阶段才进行距离搜索。

四、k-means 聚类

练习 25: k-means 聚类. 给定样本集合

$$X = \begin{pmatrix} 0 & 0 & 1 & 5 & 5 \\ 2 & 0 & 0 & 0 & 2 \end{pmatrix},$$

用 k-means 将样本聚为两类，初始质心为 $(0,0)^T$ 、 $(5,2)^T$ 。

5 个样本为

$$(0,2)^T, (0,0)^T, (1,0)^T, (5,0)^T, (5,2)^T.$$

初始质心

$$\mu_1^{(0)} = (0,0)^T, \quad \mu_2^{(0)} = (5,2)^T.$$

第一次分配时，前三个样本距离 μ_1 更近，后两个样本距离 μ_2 更近，因此

$$C_1 = \{(0,2)^T, (0,0)^T, (1,0)^T\}, \quad C_2 = \{(5,0)^T, (5,2)^T\}.$$

更新质心：

$$\mu_1^{(1)} = \left(\frac{1}{3}, \frac{2}{3}\right)^T, \quad \mu_2^{(1)} = (5,1)^T.$$

用新质心重新分配，样本归属不变，因此算法收敛。最终聚类结果即上面的 C_1, C_2 。

五、聚类算法选择

练习 26: 聚类算法选择. 对于下图所示的数据分布，判断宜采用哪类聚类算法，说明其基本原理、两个重要参数及参数取值对结果的影响。



图中簇呈非凸、弯曲形状，并含有离群噪声点，不适合用 k-means 这类偏向球形簇的算法。宜采用**密度聚类**，典型算法为 DBSCAN。

DBSCAN 的基本思想是：若某点 ε 邻域内样本数不少于 MinPts，则该点为核心点；从核心点出发，把密度可达的点不断并入同一簇；不能并入任何簇的点视为噪声。两个重要参数是邻域半径 ε 和最小邻域样本数 MinPts。 ε 太小会把一个簇切碎并产生过多噪声，太大则可能把相邻簇合并；MinPts 太小会把噪声误认为簇，太大则会漏掉稀疏簇。

9. 第 9 章：神经网络

一、TensorFlow 神经网络网页与二分类网络模型

练习 27: TensorFlow 神经网络网页与二分类网络模型. 根据 TensorFlow 神经网络学习网页及图中二分类网络模型, 解释图中 1-8 的含义, 并计算该网络的参数数量。



(1) 图中 1-8 的含义如下。

编号	含义
1	训练集与测试集划分比例
2	批量大小, 即一次参数更新使用的样本数
3	训练轮数 Epoch
4	学习率
5	激活函数
6	正则化方式
7	正则化系数
8	训练损失与测试损失, 用于观察经验误差和泛化误差

(2) 图中实际选用 2 个输入特征, 6 个隐藏层, 每个隐藏层 7 个神经元, 输出层为 1 个二分类输出。参数量为

$$(2 \times 7 + 7) + 5(7 \times 7 + 7) + (7 \times 1 + 1) = 21 + 280 + 8 = 309.$$

因此该网络共有 309 个可训练参数。

二、名词解释

练习 28: 名词解释. 解释以下概念: 早停法 (Early stopping)、暂退法 (Dropout)、梯度弥散。


早停法 训练过程中监控验证集性能, 当验证误差不再下降或开始上升时停止训练, 以避免过拟合。

暂退法 Dropout, 在训练时以一定概率随机将部分神经元输出置零, 使网络不能过度依赖某些局部特征, 相当于一种正则化方法。

梯度弥散 深层网络反向传播时, 梯度在多层链式相乘后逐渐变得很小, 导致靠近输入层的参数更新缓慢甚至难以训练。

五、BP 神经网络一次迭代

练习 29: BP 神经网络一次迭代. 针对图中神经网络, 激活函数为 $\tanh$, 损失函数为带 $1/2$ 系数的平方误差, 学习率 $\eta = 0.5$ 。计算 h_1, h_2, o_1, o_2 的误差信号, 并更新 w_4, w_8, w_{01} 。



采用图中权重连接关系: $w_1 : x_1 \rightarrow h_1$, $w_2 : x_1 \rightarrow h_2$, $w_3 : x_2 \rightarrow h_1$, $w_4 : x_2 \rightarrow h_2$; $w_5 : h_1 \rightarrow o_1$, $w_6 : h_1 \rightarrow o_2$, $w_7 : h_2 \rightarrow o_1$, $w_8 : h_2 \rightarrow o_2$ 。激活函数为 $\tanh z$, 其导数为 $1 - \tanh^2 z$ 。前向传播得

$$net_{h_1} = 0.3825, \quad h_1 = 0.364877,$$

$$net_{h_2} = 0.3900, \quad h_2 = 0.371360,$$

$$net_{o_1} = 0.931631, \quad o_1 = 0.731353,$$

$$net_{o_2} = 0.968443, \quad o_2 = 0.748019.$$

以下采用误差信号

$$\delta_j = -\frac{\partial E}{\partial net_j}.$$

输出层

$$\delta_{o_1} = (y_1 - o_1)(1 - o_1^2) = -0.335518,$$

$$\delta_{o_2} = (y_2 - o_2)(1 - o_2^2) = 0.106585.$$

隐藏层

$$\delta_{h_1} = (1 - h_1^2)(w_5 \delta_{o_1} + w_6 \delta_{o_2}) = -0.074762,$$

$$\delta_{h_2} = (1 - h_2^2)(w_7 \delta_{o_1} + w_8 \delta_{o_2}) = -0.094086.$$

用 $w \leftarrow w + \eta \delta \cdot input$, $\eta = 0.5$, 得到

$$w'_4 = 0.3 + 0.5(-0.094086)(0.1) = 0.295296,$$

$$w'_8 = 0.55 + 0.5(0.106585)(0.371360) = 0.569791,$$

$$w'_{01} = 0.35 + 0.5(-0.074762) = 0.312619.$$

六、BGD 的 BP 神经网络训练步骤

练习 30: BGD 的 BP 神经网络训练步骤. 简述采用批量梯度下降 (BGD) 的 BP 神经网络训练步骤。

批量梯度下降的 BP 训练步骤如下: 初始化网络权重和偏置; 对整个训练集做前向传播, 计算每个样本输出和总损失; 从输出层开始反向传播, 计算各层误差信号; 对全体训练样本的梯度求和或求平均; 用平均梯度一次性更新所有参数; 在验证集上检查性能并判断是否达到停止条件; 重复以上过程直到收敛或达到最大轮数。

七、Softmax 与交叉熵

练习 31: Softmax 与交叉熵. 10 分类网络输出层采用 Softmax。真实标记第 6 维为 1，网络输出为

$$(0.2, 0.1, 0, 0, 0, 0.4, 0, 0.15, 0.15, 0)^T.$$

计算交叉熵损失；若前一隐层神经元输出 $h = 0.128$ ，连接权重为

$$W = (0.1, -0.1, 0.2, -0.2, 0.3, -0.3, 0.4, -0.4, 0.5, -0.5)^T,$$

学习率 $\eta = 0.1$ ，更新该权重向量。

(1) 真实类别是第 6 类，预测概率为 0.4，因此交叉熵损失为

$$L = -\log 0.4 = 0.9163.$$

(2) Softmax 与交叉熵组合时，输出层第 j 个权重的梯度为

$$\frac{\partial L}{\partial W_j} = h(\hat{y}_j - y_j).$$

这里 $h = 0.128$ 、 $\eta = 0.1$ ，所以

$$W' = W - 0.1 \times 0.128(\hat{y} - y).$$

代入得

$$W' = \begin{pmatrix} 0.09744 \\ -0.10128 \\ 0.20000 \\ -0.20000 \\ 0.30000 \\ -0.29232 \\ 0.40000 \\ -0.40192 \\ 0.49808 \\ -0.50000 \end{pmatrix}.$$

10. 第 10 章：深度学习

九、卷积层参数量

练习 32: 卷积层参数量. 一个卷积神经网络输入为 $32 \times 32 \times 3$ 图像，第一个隐藏层卷积核大小为 5×5 ，共有 10 个卷积核。计算该层参数总量，含偏置参数。

输入通道数为 3，每个卷积核大小为 5×5 ，因此一个卷积核含

$$5 \times 5 \times 3 = 75$$

个权重。每个卷积核再配一个偏置参数，共 76 个参数。该层有 10 个卷积核，所以总参数量为

$$10 \times (75 + 1) = 760.$$